SISTEM REKOMENDASI DETEKSI PENYAKIT KUNING PADA BAYI MENGGUNAKAN *CONVOLUTIONAL NEURAL NETWORK* BERBASIS CITRA KULIT

TUGAS AKHIR

Oleh :

Nama : Adrian Maulana Fauzi

NPM : 217006014

PROGRAM STUDI INFORMATIKA FAKULTAS TEKNIK

UNIVERSITAS SILIWANGI TASIKMALAYA

2025

LEMBAR PENGESAHAN TUGAS AKHIR

SISTEM REKOMENDASI DETEKSI PENYAKIT KUNING PADA BAYI MENGGUNAKAN *CONVOLUTIONAL NEURAL NETWORK* BERBASIS CITRA KULIT

TUGAS AKHIR

Oleh:
Adrian Maulana Fauzi
217006014

Menyetujui,
Tasikmalaya, Mei 2025

Pembimbing I,	Pembimbing II,
Ir. Andi Nur Rachman, M.T.	**Ir. Cecep Muhamad Sidik R, M.T.**
NIDN. 0412088503	NIDN. 0429068401

Menyetujui,

Dekan Fakultas Teknik Universitas Siliwangi Tasikmalaya	Ketua Jurusan Informatika
Prof. Dr. Eng. Ir. H. Aripin., IPU	**Ir. Rianto., S.T., M.T., MTA**
NIP. 19670816 1999603 1 001	NIDN. 0424128401

PENGESAHAN PENGUJI SIDANG TUGAS AKHIR

SISTEM REKOMENDASI DETEKSI PENYAKIT KUNING PADA BAYI MENGGUNAKAN *CONVOLUTIONAL NEURAL NETWORK* BERBASIS CITRA KULIT

TUGAS AKHIR

Oleh:
Adrian Maulana Fauzi
217006014

Telah dipertanggungjawabkan di dalam Sidang Tugas akhir
Pada Tanggal Mei 2025

Tim Penguji Sidang Akhir

Siti Yuliyanti, S.T., M.Kom. **(_____)**
Ketua Sidang TA

Vega Purwayoga, S.Kom., M.Kom. **(_____)**
Anggota Sidang TA

Pembimbing I,	Pembimbing II,
Ir. Andi Nur Rachman, M.T.	**Ir. Cecep Muhamad Sidik R, M.T.**
NIDN. 0412088503	NIDN. 0429068401

JURUSAN INFORMATIKA
FAKULTAS TEKNIK UNIVERSITAS SILIWANGI

LEMBAR PERNYATAAN KEASLIAN

TUGAS AKHIR

Saya yang bertanda tangan dibawah ini:

Nama : Adrian Maulana Fauzi

NPM : 217006014

Jurusan/Program Studi : Informatika

Menyatakan bahwa Tugas Akhir yang

berjudul:

Sistem Rekomendasi Deteksi Penyakit Kuning Pada Bayi Menggunakan *Convolutional Neural Network* Berbasis Citra Kulit

Benar-benar merupakan hasil karya pribadi dan bukan merupakan hasil karya orang lain atau pihak manapun, serta **BUKAN PLAGIAT**. Seluruh sumber yang dijadikan rujukan dan dikutip dalam laporan Tugas Akhir ini telah saya nyatakan dengan benar. Apabila dikemudian hari pernyataan saya ini tidak benar, maka saya bersedia menanggung semua akibat atau sanksi yang berlaku.

Tasikmalaya, Mei 2025

Adrian Maulana Fauzi
217006014

ABSTRACT

Jaundice in infants due to hyperbilirubinemia has the potential to cause kernicterus, so early detection in a timely manner is essential. Invasive methods such as direct blood sampling can be stressful for infants, while current non-invasive methods have limited accessibility. This study developed a recommendation system for non-invasive jaundice detection based on infant skin image analysis using a deep learning approach. A DeepLabv3+ Convolutional Neural Network (CNN) architecture was implemented for simultaneous segmentation of relevant skin areas, and EfficientNetb3 for severity classification based on the Kramer Method. The results showed that the CNN segmentation model achieved an average accuracy of 80.3% and an average classification accuracy of 88.7%. This system is not only able to detect jaundice non-invasively but also provides treatment recommendations according to the classified severity. This study has the potential to be further developed through integration into mobile devices, expansion of datasets with more diverse skin types, and exploration of other algorithms to improve the performance and accuracy of the detection system.

Keywords: Recommendation System, Jaundice, Infants, Convolutional Neural Network, Kramer Method.

ABSTRAK

Penyakit kuning pada bayi akibat hiperbilirubinemia berpotensi menyebabkan kernikterus, sehingga deteksi dini secara tepat waktu sangat dibutuhkan. Metode invasif seperti pengambilan sampel darah langsung dapat membuat stres pada bayi, sementara metode non-invasif saat ini memiliki keterbatasan aksesibilitas. Penelitian ini mengembangkan sistem rekomendasi deteksi penyakit kuning non-invasif berbasis analisis citra kulit bayi menggunakan pendekatan *deep learning*. Sebuah arsitektur *Convolutional Neural Network* (CNN) DeepLabv3+ diimplementasikan untuk segmentasi simultan area kulit relevan, dan EfficientNetb3 untuk klasifikasi tingkat keparahan berdasarkan Metode Kramer. Hasil penelitian menunjukkan bahwa model CNN segmentasi mencapai akurasi rata-rata sebesar 80,3% dan akurasi klasifikasi rata-rata sebesar 88,7%. Sistem ini tidak hanya mampu mendeteksi penyakit kuning secara non-invasif tetapi juga memberikan rekomendasi penanganan sesuai dengan tingkat keparahan yang terklasifikasi. Penelitian ini memiliki potensi untuk dikembangkan lebih lanjut melalui integrasi ke perangkat *mobile*, perluasan dataset dengan variasi jenis kulit yang lebih beragam, serta eksplorasi algoritma lainnya untuk meningkatkan kinerja dan akurasi sistem deteksi.

Kata Kunci: Sistem Rekomendasi, Penyakit Kuning, Bayi, *Convolutional Neural Network*, Metode Kramer.

MOTTO DAN PERSEMBAHAN

MOTTO

"Selesaikan apa yang sudah kamu mulai"

PERSEMBAHAN

Dengan penuh sukacita, skripsi ini saya dedikasikan kepada orang tua tercinta, Ayahanda dan Ibunda, ketulusannya dari hati atas do'a yang tak pernah putus, semangat yang tak ternilai. Serta kekasih tercinta yang selalu membantu penyusunan skripsi ini dalam suka maupun duka.

KATA PENGANTAR

Puji syukur kehadirat Allah Swt yang telah melimpahkan rahmat, taufik, dan hidayah-Nya sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul "Sistem Rekomendasi Deteksi Penyakit Kuning pada Bayi menggunakan *Convolutional Neural Network* Berbasis Citra Kulit".

Penelitian ini tidak akan terwujud tanpa dukungan, bimbingan, dan do'a dari berbagai pihak. Oleh karena itu, penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Dekan Fakultas Teknik Universitas Siliwangi, Prof. Dr. Eng. Ir. Aripin atas bimbingan dan dukungan yang diberikan selama menempuh studi di Fakultas Teknik.
2. Ketua Program Studi Informatika, Ir. Rianto, S.T., M.T. yang telah memberikan arahan dan kesempatan dalam penyusunan Tugas Akhir.
3. Dosen Pembimbing Ir. Andi Nur Rachman, M.T. dan Cecep Muhamad Sidik R., M.T. atas bimbingan, saran, dan motivasi yang telah diberikan selama bimbingan Tugas Akhir.
4. Orang tua tercinta, yang selalu memberikan doa, dukungan moral, dan materil tanpa henti. Kasih sayang dan pengorbanan menjadi sumber inspirasi dan semangat dalam menyelesaikan Tugas Akhir.
5. Teman-teman dan rekan-rekan seperjuangan, yang telah memberikan dukungan, bantuan, serta berbagi pengetahuan dan pengalaman selama proses penyusunan Tugas Akhir.

6. Diri Sendiri, yang terus bertahan dan berjuang demi mencapai tujuan serta harapan.
7. Kekasih, yang telah setia mendampingi saya melalui setiap tantangan dalam menyelesaikan skripsi ini. Terima kasih atas dukungan, pengertian, dan semangat yang tak pernah putus.

Penulis menyadari bahwa Tugas Akhir ini masih jauh dari kesempurnaan. Oleh karena itu, saran dan kritik yang membangun sangat penulis harapkan untuk perbaikan di masa mendatang. Semoga Tugas Akhir ini dapat memberikan manfaat dan kontribusi positif bagi perkembangan ilmu pengetahuan.

Tasikmalaya, Mei 2025

Penulis

DAFTAR ISI

LEMBAR PENGESAHAN TUGAS AKHIR i

PENGESAHAN PENGUJI SIDANG TUGAS AKHIR ii

LEMBAR PERNYATAAN KEASLIAN TUGAS AKHIR iii

ABSTRACT iv

ABSTRAK v

MOTTO DAN PERSEMBAHAN vi

KATA PENGANTAR vii

DAFTAR ISI ix

DAFTAR GAMBAR xii

DAFTAR TABEL xiii

DAFTAR LAMPIRAN xiv

BAB I PENDAHULUAN I-1

1.1 Latar Belakang I-1

1.2 Rumusan Masalah I-5

1.3 Tujuan Penelitian I-5

1.4 Manfaat Penelitian I-5

1.5 Batasan Masalah I-6

BAB II LANDASAN TEORI II-1

2.1 Penelitian Terkait II-1

2.2 Landasan Teori II-3

2.2.1 Penyakit Kuning pada Bayi II-3

2.2.2 Citra Digital II-4

2.2.3 *Machine Learning* II-5

2.2.4 *Deep Learning* II-6

2.2.5 *Convolutional Neural Network* (CNN) II-7
2.2.6 DeepLabv3+ II-14
2.2.7 EfficentNetB3 ..... II-17
2.2.8 Roboflow II-19
2.2.9 Metode Kramer II-20
BAB III METODOLOGI PENELITIAN III-1
3.1 Peta Jalan (*Roadmap*) Penelitian III-1
3.2 Tahapan Penelitian III-3
3.2.1 Studi Literatur III-3
3.2.2 Akuisisi Data III-3
3.2.3 Pra Proses Data III-4
3.2.4 Segmentasi III-4
3.2.5 Klasifikasi III-5
3.2.6 Evaluasi III-6
3.2.7 *Deployment* III-6
3.2.8 Pengujian III-7
BAB IV HASIL DAN PEMBAHASAN IV-1
4.1 Akuisisi Data IV-1
4.2 Pra Proses Data IV-1
4.2.1 *Labelling* IV-2
4.2.2 *Resize* Gambar IV-2
4.2.3 *Split Validation* IV-3
4.2.4 Augmentasi IV-4
4.3 Segmentasi IV-5
4.3.1 Buat Model Segmentasi IV-5

4.3.2 Pelatihan Model IV-6
4.4 Klasifikasi IV-7
4.4.1 *Load Data* IV-8
4.4.2 Inisiasi *Load* dan *Split Data* IV-8
4.4.3 Buat Model EfficientNetB3 ..... IV-10
4.4.4 *Training Phase 1* IV-11
4.4.5 *Training Phase 2* IV-12
4.5 Evaluasi IV-13
4.5.1 Model Segmentasi IV-13
4.5.2 Model Klasifikasi IV-14
4.6 Deployment IV-17
4.7 Pengujian IV-18
BAB V KESIMPULAN DAN SARAN V-1
DAFTAR PUSTAKA 1

DAFTAR GAMBAR

Gambar 2. 1 Arsitektur *Convolutional Neural Network* II-8
Gambar 2. 2 Proses pada *Convolutional Layer*..... II-9
Gambar 2. 3 Operasi *Max Pooling*..... II-10
Gambar 2. 4 *Dropout* II-13
Gambar 2. 5 Arsitektur Model DeepLabv3+ II-16
Gambar 2. 6 Arsitektur EffcientNetB3 ..... II-18
Gambar 2. 7 Tingkat Penyakit Kuning berdasarkan Metode Kramer..... II-20
Gambar 3. 1 *Roadmap* Penelitian *Artificial Intelligence Research Group*..... III-1
Gambar 3. 2 Tahapan Penelitian III-3
Gambar 4. 1 Akuisisi Data.....IV-1
Gambar 4. 2 *Labelling*.....IV-2
Gambar 4. 3 *Resize* Gambar.....IV-3
Gambar 4. 4 *Split Validation*.....IV-4
Gambar 4. 5 Augmentasi.....IV-5
Gambar 4. 6 *Confusion Matrix* Model Segmentasi.....IV-14
Gambar 4. 7 *Confusion Matrix* Lengan/Kaki.....IV-16
Gambar 4. 8 *Confusion Matrix* Paha.....IV-16
Gambar 4. 9 *Confusion Matrix* Perut IV-16
Gambar 4. 10 *Confusion Matrix* Telapak Tangan/Kaki.....IV-16
Gambar 4. 11 *Confusion Matrix* Wajah IV-16
Gambar 4. 12 Hasil *Deployment* IV-17

DAFTAR TABEL

Tabel 2.1 Penelitian Terkait II-1
Tabel 4. 1 Hasil Pemodelan Segmentasi IV-13
Tabel 4. 2 Hasil Pemodelan Klasifikasi IV-15
Tabel 4. 3 Hasil Pengujian IV-18

DAFTAR LAMPIRAN

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perubahan warna pada sklera mata dan warna kulit menjadi kuning merupakan gejala utama yang tampak pada penyakit kuning (*jaundice*) pada bayi (Akmal Dzulkifli et al., 2018). Penyakit kuning disebabkan oleh tingginya kadar bilirubin dalam darah pasien akibat belum matangnya fungsi hati, yang dikenal sebagai hiperbilirubinemia (Brits et al., 2018). Hiperbilirubinemia yang parah dapat berkembang menjadi Ensefalopati bilirubin akut atau kernikterus, yang memiliki risiko kematian signifikan pada bayi (Xue et al., 2023). Berdasarkan riset kesehatan dasar (Riskesdas, 2015) menunjukan angka kejadian hiperbilirubinemia pada bayi di Indonesia sebesar 51,47% dengan faktor penyebabnya yaitu Kelainan Kongenital, 2,8%, Sepsis 12%, Sectio Caesarea 18,9%, Prematur 33,3%, BBLR 42,9%, dan Asfiksia 51%.

Diagnosis Hiperbilirubinemia dapat dilakukan dengan mengambil sampel darah dari pasien untuk pengujian Bilirubin Serum Total (TSB). Namun, jenis pengujian ini bersifat invasif dan menyebabkan stres serta ketidaknyamanan pada bayi, sehingga metode non-invasif lebih diutamakan. Salah satu metode klinis yang sering digunakan adalah Metode Kramer, yaitu pengamatan distribusi warna kuning pada tubuh bayi yang dibagi menjadi lima zona. Metode ini digunakan untuk memperkirakan kadar bilirubin dalam darah berdasarkan area tubuh yang terkena warna kuning (Kramer, 1969). Kemudian, Bilirubin Transkutan (TcB) merupakan

teknik non-invasif untuk menghitung kadar bilirubin (Weaver et al., 2018). Tetapi, metode ini tidak tersedia di semua fasilitas kesehatan (Alsaedi, 2018).

Berbagai penelitian sebelumnya telah mengembangkan teknik non-invasif untuk mendeteksi penyakit kuning, namun metode yang digunakan masih memiliki keterbatasan dan belum sepenuhnya optimal. Penelitian yang dilakukan (Xue et al., 2023) penggunaan JCard untuk mendeteksi penyakit kuning menunjukan bahwa alat ini memiliki tingkat aksesibilitas yang tinggi bagi orang tua, karena dapat digunakan untuk mendeteksi penyakit kuning secara mandiri di rumah. Namun, JCard memiliki kelemahan, yaitu kurang akurat dalam mendeteksi kadar bilirubin yang tinggi, sehingga dapat menyebabkan terabaikannya diagnosis pada kasus penyakit kuning yang berat. Penelitian selanjutnya (Bhagat et al., 2024) menyatakan teknik non-invasif menggunakan citra digital yang dilakukan dalam penelitian ini sangat efektif dalam penggunaanya, karena dapat mengurangi ketidaknyamanan dan risiko pada bayi. Tetapi, algoritma NuSVC yang digunakan dalam penelitian ini mempunyai akurasi yang rendah yaitu 62,50%, tingkat akurasi ini dapat memengaruhi konsistensi dan keandalan dalam deteksi penyakit kuning.

Penelitian lainnya yang dilakukan oleh (Zhang et al., 2023) menggunakan model *deep learning* ResNet18 untuk klasifikasi gambar MRI multimodal dalam mendeteksi *Encephalopathy* Bilirubin Akut (ABE) pada 177 neonatus, dengan akurasi tertinggi 80.8% pada kombinasi T1 dan T2. Kekurangan penelitian meliputi ukuran sampel kecil, desain model 2D yang tidak memanfaatkan informasi 3D, dan kinerja buruk gambar ADC. Berdasarkan penelitian-penelitian sebelumnya, belum ada sistem yang dapat mendeteksi tingkat keparahan penyakit kuning pada bayi.

Celah penelitian ini menunjukan perlunya sistem yang dapat mendeteksi tingkat keparahan penyakit kuning pada bayi.

CNN dikenal efektif dalam mengenali pola visual pada gambar dan menghasilkan tingkat akurasi tinggi, dibuktikan dengan penelitian yang dilakukan oleh (Halder et al., 2022) Menggunakan CNN untuk mendeteksi *scabies* menggunakan citra digital, akurasi yang didapatkan yaitu 97,25%. Penelitian (Iswantoro & Handayani UN, 2022) menerapkan CNN untuk mengklasifikasikan penyakit pada tanaman jagung berbasis citra digital, mendapatkan akurasi sebesar 97,5%. Penelitian yang dilakukan (Nurona Cahya et al., 2021) menggunakan model CNN untuk klasifikasi penyakit mata berbasis citra digital dengan arsitektur Alexnet mencapai akurasi yang tinggi yaitu 98,47%. Penelitian selanjutnya (Rahman et al., 2024) menerapkan pemodelan CNN untuk mendeteksi penyakit daun teh di Bangladesh menggunakan citra digital, mendapatkan nilai akurasi sebesar 96,65%. Dapat disimpulkan bahwa CNN efektif digunakan untuk mendeteksi dan mengklasifikasikan berbagai jenis penyakit berbasis citra digital, baik pada manusia, maupun tumbuhan.

Penelitian ini mengusulkan CNN dengan arsitektur DeepLabv3+ untuk segmentasi dan CNN dengan arsitektur EfficentNetB3 untuk klasifikasi tingkat keparahan penyakit kuning berdasarkan citra digital. DeepLabv3+ terbukti efektif dalam melakukan segmentasi objek, dibuktikan dengan penelitian (Wang et al., 2024) untuk segmentasi citra penginderaan jauh, akurasi keseluruhan yang didapatkan yaitu 86,11%. Kemudian penelitian selanjutnya yang dilakukan oleh (Yu et al., 2022) untuk segementasi citra PoISAR (*polarimetric synthetic aperture*

radar), akurasi rata-rata yang didapatkan yaitu 93,89%. Dengan hasil ini, bahwa arsitektur DeepLabv3+ dapat diandalkan untuk melakukan segmentasi citra penyakit kuning pada bayi.

EfficentNetB3 juga terbukti efektif dalam mengklasifikasikan citra, dibuktikan dengan penelitian yang dilakukan oleh (George & S, 2024) untuk klasifikasi kanker payudara, menghasilkan akurasi sebesar 95,25%. Kemudian penelitian lainnya yang dilakukan oleh (Islam et al., 2024) penelitian ini membandingkan beberapa arsitektur untuk klasifikasi (OSCC) Karsinoma sel skuamosa oral, yaitu EfficientNetB3, DenseNet121, ResNet101, dan VGG16. Akurasi tertinggi didapatkan oleh EfficientNetB3 dengan akurasi 99,64%. Dengan beberapa penelitian tersebut, menunjukan bahwa EfficentNetB3 efektif dalam melakukan klasifikasi citra.

Berdasarkan masalah yang dipaparkan, penelitian ini dilakukan untuk mendeteksi penyakit kuning dengan mengukur tingkat keparahan penyakit kuning pada bayi menggunakan CNN dengan arsitektur DeepLabv3+ untuk segmentasi, CNN dengan arsitektur EffcientNetB3 untuk klasikasi, dan Metode Kramer sebagai parameternya. Kemudian menguji seberapa efektif algoritma tersebut dalam mendeteksi penyakit kuning pada bayi serta memberikan rekomendasi penanganannya. Penggunaan CNN diharapkan mampu membantu proses deteksi penyakit kuning dengan akurasi tinggi, sehingga dapat mempercepat penanganan dan mengurangi risiko komplikasi serius seperti Kernikterus.

1.2 Rumusan Masalah

Berdasarkan latar belakang masalah yang telah dipaparkan, rumusan masalah pada penelitian ini yaitu:

1. Bagaimana akurasi algoritma CNN dalam melakukan segmentasi citra digital bagian tubuh bayi untuk mendeteksi penyakit kuning?
2. Bagaimana akurasi algoritma CNN dalam mengklasifikasikan tingkat keparahan penyakit kuning pada bayi dan memberikan rekomendasi penanganan yang sesuai?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah, tujuan penelitian ini adalah:

1. Menganalisis akurasi algoritma CNN dalam melakukan segmentasi citra digital bagian tubuh bayi.
2. Mengevaluasi akurasi algoritma CNN dalam mengklasifikasikan tingkat keparahan penyakit kuning pada bayi berdasarkan citra digital dan memberikan rekomendasi penanganan yang sesuai.

1.4 Manfaat Penelitian

Adapun manfaat dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi pada pengembangan model CNN dalam deteksi penyakit kuning pada bayi berbasis citra kulit.
2. Menyediakan solusi deteksi penyakit kuning yang lebih cepat, akurat, dan non-invasif, mengurangi risiko komplikasi dan ketidaknyaman bagi bayi, dan memberikan rekomendasi penanganan.

3. Meningkatkan kesadaran dan kualitas layanan kesehatan dalam deteksi dini penyakit kuning, mengurangi morbiditas dan mortalitas bayi.

1.5 Batasan Masalah

Batasan masalah yang ditentukan dalam penelitian ini adalah sebagai berikut:

1. Penelitian ini berfokus pada deteksi penyakit kuning bayi menggunakan algoritma dan CNN berbasis citra digital kulit.
2. Dataset yang digunakan merupakan gambar digital kulit bayi dengan fokus pada warna kulit bayi cerah.
3. Parameter yang digunakan hanya menggunakan metode Kramer tanpa mempertimbangkan tingkat kekuningan kulit bayi.

BAB II

LANDASAN TEORI

2.1 Penelitian Terkait

Berdasarkan kajian literatur, deteksi penyakit berbasis citra digital telah banyak diterapkan pada berbagai kasus medis seperti deteksi penyakit kulit, hingga deteksi penyakit kuning pada bayi. Beberapa penelitian memanfaatkan pengolahan citra kulit untuk mendeteksi kelainan, dengan fokus pada pola dan warna kulit. Model berbasis *Machine Learning* dan *Deep Learning* sering digunakan untuk mengolah data citra dan memberikan akurasi yang cukup akurat, meskipun performa model sering dipengaruhi oleh keberagaman dataset.

Pendekatan berbasis *Convolutional Neural Network* (CNN) semakin banyak digunakan karena kemampuannya yang sangat baik untuk mengenali citra. Namun, penerapan CNN dalam mendeteksi penyakit kuning pada bayi belum banyak dilakukan. Penelitian ini mengembangkan model berbasis CNN dengan arsitektur DeepLabv3 untuk segmentasi dan arsitektur EffcientNetB3 untuk klasifikasi. Dengan memanfaatkan algoritma CNN, diharapkan hasil deteksi dapat lebih akurat dalam diagnosis dini penyakit kuning pada bayi. Berikut adalah *State of the art* penelitian terkait yang dapat dilihat pada tabel 2.1.

Tabel 2.1 Penelitian Terkait

No	Judul	Metode/Algoritma	Hasil Penelitian
1	*Comparative Analysis of Classification of Neonatal Bilirubin by Using Various Machine Learning Approaches* (Bhagat et al., 2024)	NuSVC, *Random Forest*, ADABoost, dan *Extra Trees*.	Algoritma NuSVC mencapai akurasi paling tinggi yaitu 62,50%, *precision* 61,90%, dan *recall* 56,52% dalam mengklasifikasi penyakit kuning.

2	*Non-invasive and Non-Contact Automatic Jaundice Detection of Infants Based on Random Forest* (Khanam et al., 2023)	*Random Forest*	Sistem deteksi *jaundice* non-invasif menggunakan algoritma *Random Forest* mencapai akurasi 99,22%, *precision* 99,74%, *recall* 99,20%, dan skor F1 99,46%.
3	*Deep Learning Network with Spatial Attention Module for Detecting Acute Bilirubin Encephalopathy in Newborns Based on Multimodal MRI* (Zhang et al., 2023)	MRI multimodal menggunakan arsitektur ResNet18	Studi ini menunjukkan bahwa model klasifikasi MRI multimodal menggunakan ResNet18 menjadikan klasifikasi terbaik dicapai dengan kombinasi gambar T1 dan T2, menghasilkan akurasi 80,80%.
4	*Classification of Lung Disease in X-Ray Images Using Gray Level Co Occurrence Matrix Method and Convolutional Neural Network* (Nurcahyati et al., 2024)	CNN dan GLCM	Hasilnya menunjukkan bahwa model CNN mencapai akurasi rata-rata 92%, sedangkan metode GLCM menghasilkan metrik yang lebih rendah 87%.
5	Pengembangan Model *Convolutional Neural Network* (CNN) untuk Klasifikasi Penyakit Kulit Berbasis Citra Digital (Imam Fathurrahman et al., 2025)	CNN	Studi ini dirancang untuk mengklasifikasikan penyakit kulit menggunakan CNN, dan mencapai akurasi sebesar 87,14%.
6	*Enhanced Skin Cancer Diagnosis Using Optimized CNN Architecture and Checkpoints for Automated Dermatological Lesion Classification* (Musthafa et al., 2024)	CNN	Studi ini mencapai akurasi yang luar biasa sebesar 97,78% untuk model CNN, precision 97,9%, *recall* 97,9%, dan *F1-score* 97,8%.
7	Deteksi Penyakit Kulit Wajah Menggunakan Tensorflow dengan Metode *Convolutional Neural Network* (Prastika et al., 2021)	CNN	Studi deteksi penyakit kulit wajah dengan jumlah 20 jenis penyakit diperoleh akurasi 99,91% dan presentase rata-rata ketepatan 80%.
8	*An automated detection of Scabies skindisease Using Image Processing and CNN* (Halder et al., 2022)	CNN	Studi deteksi penyakit *scabies* menggunakan CNN menunjukkan akurasi tinggi yaitu 97,25%.
9	*Human Skin Diseases Detection and Classification using CNN* (Ahmed et al., 2023)	CNN	Studi ini mencapai akurasi 89,45% dalam mendeteksi penyakit kanker kulit.

10	Deteksi Otomatis Jerawat Wajah Menggunakan Metode *Convolutional Neural Network* (CNN) (Sudana Putra et al., 2021)	CNN	*Convolutional Neural Network* (CNN) mencapai kisaran akurasi 99,8% hingga 100%, menunjukkan kinerja yang sangat baik dalam mengklasifikasikan gambar jerawat.
11	*A Lightweight Complex-Valued DeepLabv3+ for Semantic Segmentation of PolSAR Image* (Yu et al., 2022)	DeepLabv3+ (CNN)	Segementasi citra PoISAR, menggunakan arsitektur CNN DeepLabv3+ akurasi rata-rata yang didapatkan yaitu 93,89%.
12	*An improved semantic segmentation algorithm for high-resolution remote sensing images based on DeepLabv3+* (Wang et al., 2024)	DeepLabv3+ (CNN)	Segmentasi citra penginderaan jauh menggunakan arsitektur CNN DeepLabv3+ akurasi keseluruhan yang didapatkan yaitu 86,11%.
13	*Leveraging EfficientNet-B3 with Advanced Fine-Tuning for Precise Breast Cancer Classification* (George & S, 2024)	EfficientNetB3 (CNN)	Klasifikasi kanker payudara menggunakan arsitektur CNN EfficientNetB3 menghasilkan akurasi sebesar 95,25%.
14	*Deep Learning Approach for Enhancing Oral Squamous Cell Carcinoma with LIME Explainable AI Technique* (Islam et al., 2024)	EfficientNetB3 (CNN)	Penelitian ini membandingkan beberapa arsitektur untuk kalsifikasi (OSCC) Karsinoma sel skuamosa oral, yaitu EfficientNetB3, DenseNet121, ResNet101, dan VGG16. Akurasi tertinggi didapatkan oleh EfficientNetB3 dengan akurasi 99,64%.

2.2 Landasan Teori

2.2.1 Penyakit Kuning pada Bayi

Penyakit kuning atau bisa disebut juga *jaundice* atau *ikterus* merupakan keadaan kulit dan bagian putih mata menjadi berwarna kuning yang diakibatkan tingginya kadar bilirubin, kondisi ini umum terjadi pada bayi. Pada bayi, kadar bilirubin yang tinggi sering terjadi karena fungsi hati yang belum matang. Pada bayi dengan fungsi hati yang belum optimal, bilirubin dapat menumpuk dalam darah

sehingga menyebabkan warna kuning pada tubuh. Ikterus bisa muncul jika kadar bilirubin serum total $\geq$ 5mg / dl (86 µmol/L) (Rufaindah et al., 2022).

Penyakit kuning pada bayi dapat disebabkan oleh peningkatan kadar bilirubin, baik yang tak terkonjugasi maupun terkonjugasi. Pada bayi, ikterus dapat terjadi karena beberapa faktor, seperti prematuritas, pengaruh ASI, atau gangguan medis tertentu. Beberapa penyebab utama meliputi penyakit yang memicu kelebihan produksi bilirubin, seperti penyakit hemolitik atau defisiensi enzim, serta obstruksi saluran empedu yang mengganggu kemampuan hati untuk mengeluarkan bilirubin terkonjugasi. Gangguan dalam produksi dan ekskresi bilirubin juga dapat menjadi faktor penyebab, seperti defisiensi *enzim glucose-6-phosphate dehydrogenase* (G6PD), hipotiroidisme, galaktosemia, atau bayi dari ibu dengan diabetes (Hockenberry et al., 2015).

2.2.2 Citra Digital

Fungsi dua dimensi *f(x,y)* adalah citra digital dengan ukuran M baris dan N kolom, dimana *x* dan *y* adalah posisi koordinat spasial dan amplitudo *f* di titik koordinat *(x,y)*, yang disebut intensitas atau tingkat keabuan citra pada titik tersebut (Gonzalez & Woods, 2008). Proses digitasi dapat diartikan sebagai proses konversi data analog ke format digital. Pengolahan citra digital adalah ilmu yang mempelajari cara memperbaiki kualitas gambar, seperti meningkatkan kontras, transformasi warna, restorasi citra, mengubah rotasi, translasi, skala, dan transformasi geometrik. Pengolahan citra juga mempelajari bagaimana memilih gambar dengan karakteristik fitur yang tepat untuk dianalisis. Secara keseluruhan pengolahan citra berarti suatu cara mengusahakan suatu citra menjadi citra lain

yang lebih sempurna atau yang diinginkan. Dengan kata lain, pengolahan citra merupakan proses dengan masukan citra dan menghasilkan keluaran berupa citra yang diinginkan (Sulistiyanti et al., 2016).

Citra digital dipetakan menjadi elemen-elemen piksel berbentuk matriks dua dimensi. Setiap piksel memiliki nilai numerik yang mempresentasikan warna. Warna yang terlihat pada citra merupakan kombinasi dari tiga warna dasar, yaitu merah, hijau, dan biru atau biasa dikenal RGB. Kombinasi nilai dari ketiga komponen RGB tersebut menciptakan warna yang khas untuk setiap piksel. Pada citra dengan 256 warna, setiap piksel direpresentasikan dengan panjang 8 bit. Rentang RGB berkisar antara 0 hingga 255, yang didasarkan pada cara komputer mempresentasikan angka dalam 8 digit biner. Citra digital dapat dipresentasikan sebagai matriks yang terdiri dari *M* kolom dan *N* baris, dimana perpotongan antara kolom dan baris disebut piksel, yaitu elemen terkecil dari sebuah citra. Setiap piksel memiliki dua parameter, yaitu koordinat dan nilai intensitas atau warna. Nilai pada koordinat (x,y) dilambangkan sebagai $f(x,y)$, yang menunjukan tingkat intensitas atau warna piksel di lokasi tersebut (Kirana, 2021).

2.2.3 Machine Learning

Machine Learning atau pembelajaran mesin adalah bagian dari Kecerdasan Buatan, *Machine Learning* ini merupakan studi ilmiah tentang algoritma dan model statistik yang digunakan sistem komputer untuk melakukan tugas tertentu tanpa menggunakan instruksi eksplisit, dengan mengandalkan pola dan inferensi sebagai gantinya (Pratama, 2020). Istilah *Machine Learning* pertama kali didefinisikan oleh Arthur Samuel pada tahun 1959. Menurut Arthur, Machine Learning merupakan

suatu bidang ilmu komputer yang memberikan kemampuan pembelajaran kepada komputer untuk mengetahui sesuatu tanpa pemrograman yang jelas (Wiederhold & McCarthy, 2010).

Menurut (Wira & Putra, 2020) Machine Learning adalah teknik untuk melakukan inferensi terhadap data dengan pendekatan matematis. Inti *Machine Learning* adalah membuat model (matematis) yang merefleksikan pola-pola data.

2.2.4 Deep Learning

Deep learning atau pembelajaran mendalam merupakan sub-bidang yang spesifik dari *machine learning* dengan penerapan algoritma *artificial neural network* (jaringan syaraf tiruan) untuk mempelajari representasi data yang tidak terstruktur dalam jumlah yang besar (Pramestya, 2018). Pada *deep learning* lapisan representasi dipelajari melalui model yang disebut *neural network* (jaringan syaraf) dalam lapisan literal yang ditumpuk satu sama lain secara terstruktur.

Arsitektur *deep learning* disebut sebagai *multi layer perceptron*, yang memiliki 4 node *neuron* pada *input layer* (lapisan masukan) berfungsi sebagai jalur untuk mentransmisikan sinyal masukan ke *node* berikutnya, 2 *hidden layer* (lapisan tersembunyi) yang merupakan perantara antara input layer dengan *output layer* dan berfungsi untuk menambah instruksi logika, serta 3 *node neuron* pada *output layer* (lapisan keluaran) yang menjadi hasil akhir dari *neural network*.

Jumlah *neuron* yang diterapkan pada sebuah lapisan tersembunyi sangat mempengaruhi performa *deep learning*. Jika jumlah *node neuron* yang diterapkan pada arsitektur *deep learning* terlalu sedikit maka dapat menyebabkan model

menjadi *underfitting*. Jika jumlah *node neuron* yang diterapkan terlalu banyak maka dapat menyebabkan model menjadi *overfitting*.

2.2.5 *Convolutional Neural Network* (CNN)

Convolution Neural Network bermula dari Yann LeCun dan teman temannya berhasil melakukan klasifikasi citra kode zip menggunakan kasus khusus dari Feed Forward Neural Network Pada tahun 1989. Mulai pada tahun 2012, dimana perangkat keras *Graphical Processing Unit* (GPU) berkembang, DNN juga ikut berkembang dan bahkan sebuah CNN dapat melakukan pengenalan citra dengan akurasi yang sangat baik dan dapat menyaingi manusia pada dataset tertentu (Sugiarto et al., 2018).

Convolutional Neural Network (CNN) merupakan salah satu pengembangan dari jaringan syaraf tiruan yang terinspirasi dari jaringan syaraf manusia dan biasa digunakan pada data gambar untuk mendeteksi dan mengenali suatu objek pada sebuah gambar (Nurfita & Ariyanto, 2018). *Convolutional Neural Network* (CNN) adalah pengembangan dari *Multilayer Perceptron* (MLP) yang didesain untuk mengolah data dua dimensi. Pada CNN, setiap neuron direpresentasikan dalam bentuk dua dimensi, tidak seperti MLP yang setiap neuron hanya berukuran satu dimensi. CNN termasuk dalam *Deep Neural Network* karena kedalaman jaringan yang tinggi dan banyak diaplikasikan pada data citra (Suartika et al., 2016). CNN hampir sama dengan neural network pada umumnya yang memiliki neuron yang memiliki bobot dan bias. CNN memiliki 1 tahap *training (Supervised Backpropagation*).

Secara teknis, CNN adalah sebuah arsitektur yang dapat dilatih dan terdiri dari beberapa tahap. Masukan (*input*) dan keluaran (*output*) dari setiap tahap adalah terdiri dari beberapa array yang biasa disebut *feature map*. Setiap tahap terdiri dari tiga layer yaitu konvolusi, fungsi aktivasi *layer* dan *pooling layer*. Berikut adalah jaringan arsitektur *Convolutional Neural Network* berdasarkan penelitian (Nurhikmat, 2018) dapat dilihat pada gambar 2.1.

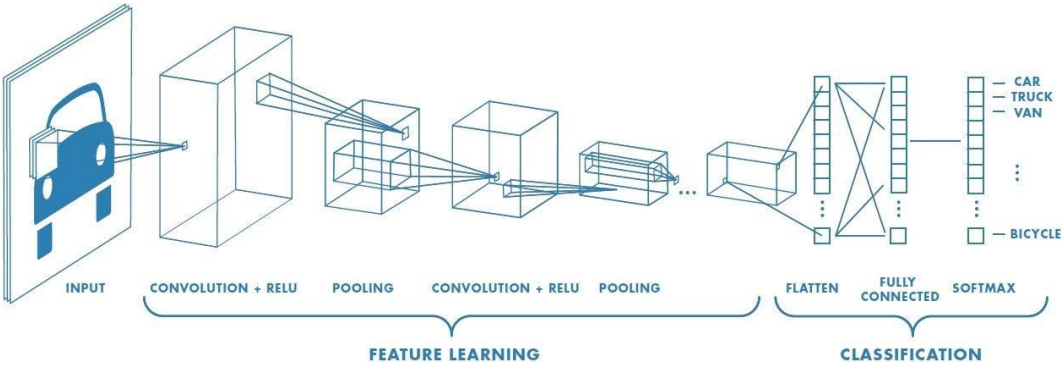

Gambar 2. 1 Arsitektur *Convolutional Neural Network*

Pada gambar 2.1 Tahap pertama pada arsitektur CNN adalah tahap konvolusi. Tahap ini dilakukan dengan menggunakan sebuah kernel dengan ukuran tertentu. Perhitungan jumlah kernel yang dipakai tergantung dari jumlah fitur yang dihasilkan. Kemudian dilanjutkan menuju fungsi aktivasi, biasanya menggunakan fungsi aktivasi ReLU (*Rectifier Linear Unit*), Selanjutnya setelah keluar dari proses fungsi aktivasi kemudian melalui proses *pooling*. Proses ini diulang beberapa kali sampai didapatkan peta fitur yang cukup untuk dilanjutkan ke *fully connected neural network*, dan dari *fully connected network* adalah *output class*.

1. Convolution Layer

Pada proses konvolusi, filter menjadi peran utama untuk proses pelatihan mesin. Seperti layaknya gambar, filter memiliki ukuran tinggi, lebar, dan tebal

tertentu. Filter ini diinisialisasi dengan nilai tertentu (*random* atau menggunakan teknik tertentu seperti Glorot), dan nilai dari filter inilah yang menjadi parameter yang akan di-*update* dalam proses *learning*. Proses konvolusi dapat dilihat pada gambar 2.2.

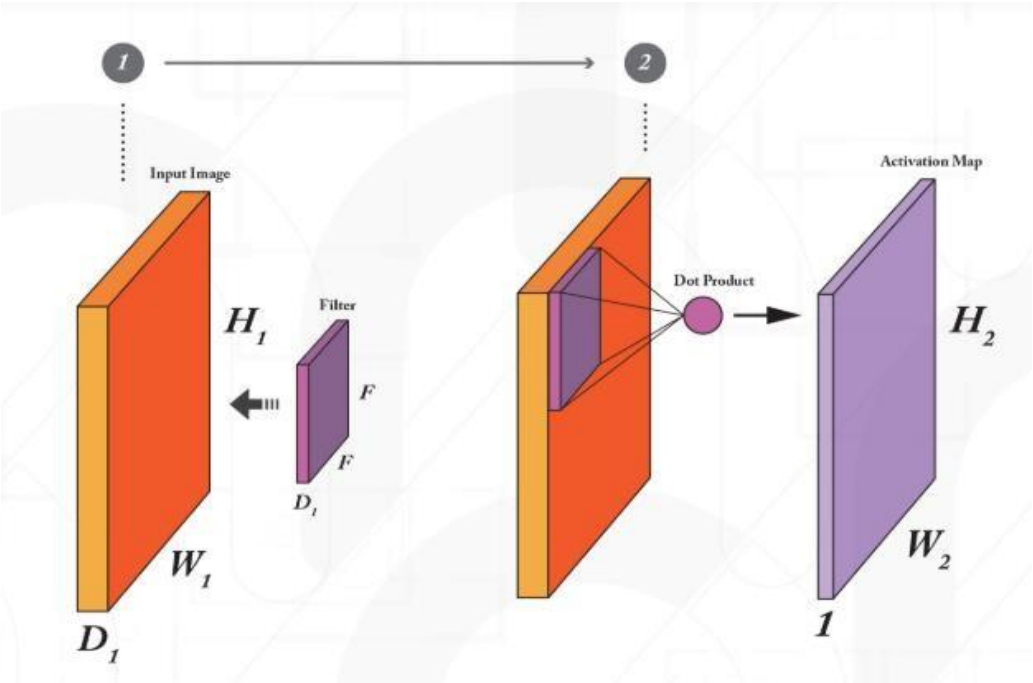

Gambar 2. 2 Proses pada *Convolutional Layer*

Gambar 2.2 menjelaskan input CNN selalu berbentuk kotak. Proses untuk gambar *non-rectangular* masih belum diketahui. Filter pun mengikuti karakteristik kotak tersebut. Parameter lapisan konvolusi terdiri dari satu set filter yang dapat dipelajari. Setiap filter kecil secara spasial (Panjang x lebar x tinggi), tetapi meluas melalui kedalaman dari volume input.

2. Operasi *Pooling*

Setelah melewati proses konvolusi kemudian hasilnya akan melalui tahap *pooling*. Fungsi dari pooling ini adalah untuk mereduksi input secara spasial (mengurangi jumlah parameter) dengan operasi *down-sampling*. Umumnya,

metode *pooling* yang digunakan adalah *max pooling* atau mengambil nilai terbesar dari bagian tersebut.

Berdasarkan penelitian (Suartika et al., 2016) *Max Pooling* adalah proses untuk meningkatkan invariansi posisi dari fitur menggunakan operasi *Max*. *Max Pooling* membagi *output* dari *Convolutional Layer* menjadi beberapa grid kecil lalu mengambil nilai maksimal dari setiap grid untuk menyusun matriks citra yang telah direduksi seperti pada gambar 2.3 Grid yang berwarna merah, hijau, kuning dan biru merupakan kelompok grid yang akan dipilih nilai maksimumnya. Sehingga hasil proses tersebut dapat dilihat pada kumpulan grid disebelah kanannya. Proses tersebut memastikan fitur yang didapatkan akan sama meskipun objek citra mengalami translasi (pergeseran).

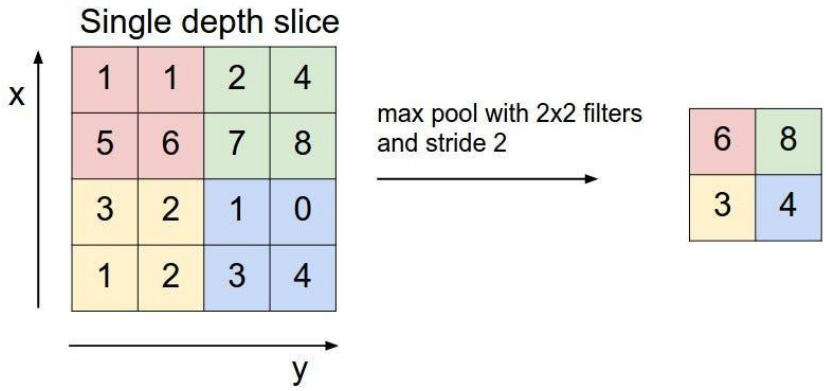

Gambar 2. 3 Operasi *Max Pooling*

Secara umum, operasi pada pooling layer dimulai dengan menerima sebuah volume berukuran:

$$W1 \times H1 \times D1 \tag{1}$$

Membutuhkan dua hiperparameter yakni:

F = ukuran bidang *receptif*

S = stride

Menghasilkan sebuah volume dengan ukuran:

$$W2 \text{ x } H2 \text{ x } D2 \tag{2}$$

dimana:

$$W2 = (W1 - F)/S + 1 \tag{3}$$

$$H2 = (H1 - F)/S + 1 \tag{4}$$

$$D2 = D1 \tag{5}$$

Memperkenalkan *zero* parameter karena menghitung fungsi input yang tetap, dan *Pooling layer* biasanya tidak memasukkan input menggunakan *zero-padding.* Pada praktiknya, hanya ada dua variasi yang terlihat pada *max pooling layer* yaitu sebuah *pooling layer* dengan F=3, S=2 (disebut juga sebagai *overlapping pooling*) dan lebih umum lagi F=2, S=2. Ukuran *pooling* dengan bidang reseptif yang lebih besar sangat merusak.

3. Fully-Connected Layer

Feature map yang dihasilkan dari *feature extraction layer* masih berbentuk *multidimensional array*, sehingga kita harus melakukan "*flatten*" atau *reshape feature map* menjadi sebuah vector agar bisa kita gunakan sebagai *input* dari *fully-connected layer*. Neuron pada *Fully Connected Layer* memiliki hubungan yang lengkap pada semua aktivasi dalam layer sebelumnya. Aktivasi tersebut kemudian di komputasi dengan sebuah perkalian matriks diikuti oleh bias *offset*. Pada dasarnya lapisan ini biasanya digunakan pada MLP (*Multi Layer Perceptron*) yang bertujuan untuk melakukan transformasi pada dimensi data agar data dapat diklasifikasikan secara linear.

Activation map yang dihasilkan dari *feature extraction layer* masih berbentuk *multidimensional array*, sehingga mau tidak mau harus dilakukan

reshape activation map menjadi suatu vektor agar bisa digunakan sebagai input dari *fully-connected layer*. Layer ini memiliki *hidden layer, activation function, output layer*, dan *loss function*. Layer ini adalah layer yang biasanya digunakan dalam penerapan *multi layer perceptron* dan bertujuan untuk melakukan transformasi pada dimensi data agar data dapat diklasifikasikan secara linear.

Setiap neuron pada *convolution layer* perlu ditransformasi menjadi data satu dimensi terlebih dahulu sebelum dapat dimasukkan ke dalam sebuah *fully-connected layer*. Karena hal tersebut menyebabkan data kehilangan informasi spasialnya dan tidak reversibel, sedangkan *fully-connected layer* hanya dapat diimplementasikan di akhir jaringan.

Convolution layer dengan ukuran kernel 1 x 1 melakukan fungsi yang sama dengan *fully-connected layer* namun dengan tetap mempertahankan karakter spasial dari data. Sehingga hal tersebut membuat penggunaan layer ini pada CNN sekarang tidak banyak dipakai.

Selain arsitektur yang telah dipaparkan, masih banyak arsitektur lain yang dapat digunakan untuk berbagai karakteristik data maupun arsitektur yang cocok untuk karakteristik/permasalahan tertentu.

4. Dropout Regularization

Dropout adalah teknik regularisasi jaringan syaraf dimana beberapa neuron akan dipilih secara acak dan tidak dipakai selama pelatihan. Neuron-neuron ini dapat dibilang dibuang secara acak. Hal ini berarti bahwa kontribusi neuron yang dibuang akan diberhentikan sementara jaringan dan bobot baru juga tidak diterapkan pada neuron pada saat melakukan *backpropagation.*

Dropout merupakan proses mencegah terjadinya *overfitting* dan juga mempercepat proses *learning*. *Dropout* mengacu kepada menghilangkan *neuron* yang berupa *hidden* maupun layer yang *visible* di dalam jaringan. Dengan menghilangkan suatu neuron, berarti menghilangkannya sementara dari jaringan yang ada. Neuron yang akan dihilangkan akan dipilih secara acak. Setiap neuron akan diberikan probabilitas yang bernilai antara 0 dan 1. Dropout dapat dilihat pada gambar 2.4.

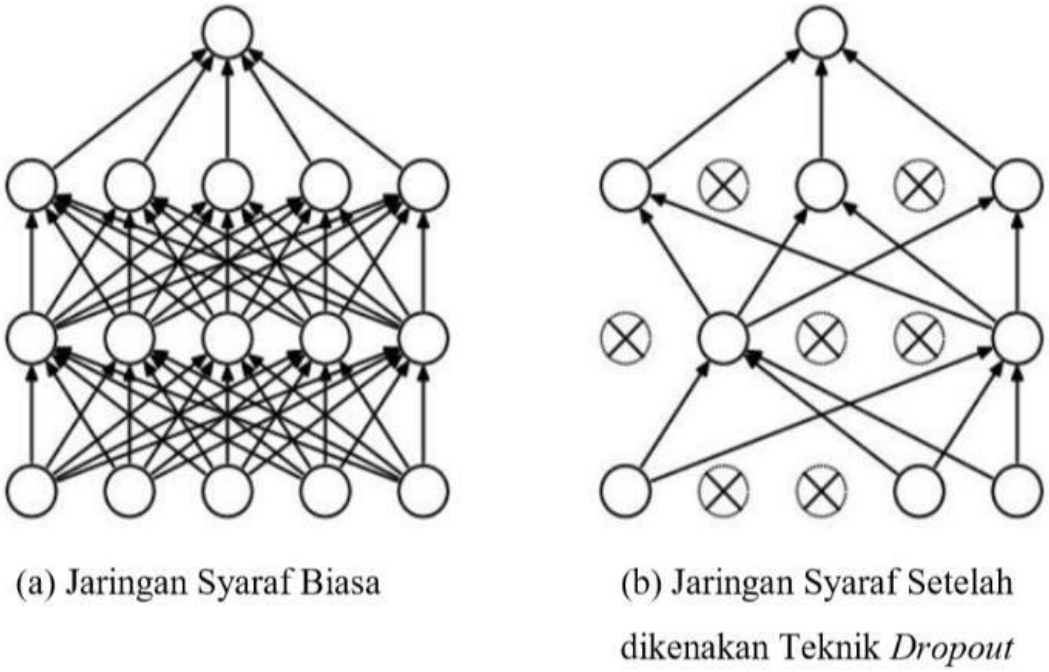

Gambar 2. 4 *Dropout*

Pada gambar 2.4 jaringan syaraf (a) merupakan jaringan syaraf biasa dengan 2 lapisan tersembunyi. Sedangkan pada bagian (b) jaringan syaraf sudah diaplikasikan teknik regularisasi *dropout* dimana ada beberapa neuron aktivasi yang tidak dipakai lagi. Teknik ini sangat mudah diimplementasikan pada model CNN dan akan berdampak pada performa model dalam melatih serta mengurangi *overfitting*.

5. Softmax Layer

Fungsi *softmax* digunakan untuk metode klasifikasi dengan jumlah kelas yang banyak, seperti regresi logistik multinomial, analisis diskriminan *linear multiclass, Naive Bayes Classifier, dan Artificial Neural Network* (ANN). *Softmax* adalah sebuah fungsi yang mengubah K-dimensi vektor 'x' yang berupa nilai sebenarnya menjadi vektor dengan bentuk yang sama namun dengan nilai dalam rentang 0-1, yang jumlahnya 1. Fungsi *softmax* digunakan dalam *layer* yang terdapat pada *neural network* dan biasanya terdapat pada layer terakhir untuk mendapatkan output. Tidak jauh berbeda dengan neuron pada umumnya *softmax neuron* menerima input lalu melakukan pembobotan dan penambahan bias. Tetapi setelah itu neuron pada *softmax layer* tidak menerapkan fungsi aktivasi melainkan menggunakan fungsi *softmax*. Dapat disimpulkan bahwa *softmax layer*, menentukan probabilitas terbesar untuk hasil kelasnya.

2.2.6 DeepLabv3+

DeepLabv3+ adalah model segmentasi gambar semantik berbasis *convolutional neural network* (CNN) yang dirancang untuk meningkatkan akurasi segmentasi, khususnya pada batas-batas objek. Model ini memanfaatkan *Atrous Spatial Pyramid Pooling* (ASPP) untuk menangkap informasi kontekstual dari berbagai skala menggunakan *atrous convolution*, yang memungkinkan model mempertahankan resolusi tinggi tanpa kehilangan detail spasial akibat *pooling* (Chen et al., 2018). Selain itu, penggunaan *depthwise separable convolution* mengurangi kompleksitas komputasi dan jumlah parameter, sehingga model tetap efisien pada berbagai skala. *Encoder* menghasilkan *feature map* dengan resolusi

rendah tetapi kaya informasi semantik, sementara *decoder* memulihkan detail objek dengan menggabungkan fitur tingkat rendah dari backbone seperti ResNet-101.

Sebagai pengembangan dari CNN, DeepLabv3+ memaksimalkan kemampuan CNN untuk menangkap pola visual dengan meningkatkan resolusi fitur melalui *atrous convolution*. Pendekatan ini memungkinkan model menangkap informasi pada berbagai tingkat hierarki tanpa peningkatan signifikan dalam beban komputasi. Dengan mekanisme *decoder* yang dirancang khusus, model ini menghasilkan segmentasi yang lebih detail, terutama di area batas objek (Chen et al., 2018). DeepLabv3+ telah diuji pada beberapa dataset benchmark seperti PASCAL VOC 2012 dengan akurasi 89.0% dan Cityscapes dengan akurasi 82.1%. Modifikasi pada arsitektur CNN seperti penggantian *max pooling* dengan *depthwise separable convolution* turut berkontribusi pada peningkatan kinerja, menjadikannya salah satu solusi unggul dalam segmentasi semantik berbasis CNN. Gambar 2.5. menampilkan arsitektur model DeepLabv3+ dan juga proses untuk menghasilkan label prediksi.

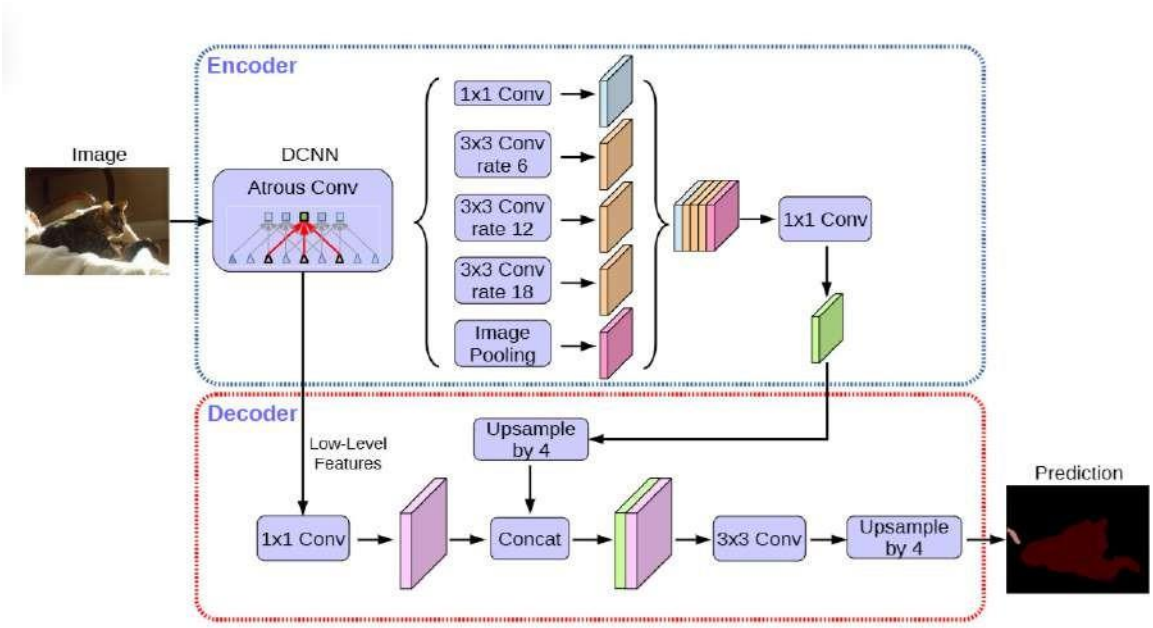

Gambar 2. 5 Arsitektur Model DeepLabv3+

Gambar 2.5 menunjukkan arsitektur DeepLabv3+, yang merupakan pengembangan dari DeepLabv3 dengan menambahkan modul *decoder* untuk meningkatkan segmentasi, terutama pada batas objek. *Encoder* pada DeepLabv3+ menggunakan *Atrous Spatial Pyramid Pooling* (ASPP) dengan *atrous convolution* pada tingkat dilasi berbeda (*rate* 6, 12, dan 18) untuk menangkap informasi multi-skala, ditambah *pooling* gambar untuk menyediakan informasi global. *Low-level feature* dari *backbone*, seperti lapisan awal ResNet sebelum *downsampling*, juga dimanfaatkan untuk mempertahankan detail spasial.

Modul *decoder* menerima keluaran dari ASPP dan *low-level feature* yang telah melalui *convolution* 1x1 untuk mengurangi dimensi saluran. Setelah penggabungan (*concatenate*), fitur tersebut diproses melalui *convolution* 3x3 untuk meningkatkan kualitas segmentasi, diikuti dengan upsampling bilinear untuk mengembalikan resolusi ke ukuran asli. Pendekatan ini memungkinkan DeepLabv3+ menghasilkan segmentasi semantik yang lebih baik, terutama pada

batas objek, dengan memadukan informasi multi-skala dari ASPP dan kemampuan pemulihan detail dari struktur *encoder-decoder*.

2.2.7 EfficentNetB3

EfficientNet-B3 adalah model *convolutional neural network* (CNN) yang merupakan bagian dari keluarga EfficientNet, yang terkenal karena pendekatan inovatifnya dalam mencapai efisiensi tinggi dengan kinerja yang kompetitif. Inti dari EfficientNet-B3 adalah metode penskalaan gabungan (*compound scaling*), yang secara simultan menyesuaikan lebar (jumlah filter), kedalaman (jumlah lapisan), dan resolusi input gambar menggunakan koefisien terpadu (Ba Alawi & Bozkurt, 2023). Pendekatan ini berbeda dari metode penskalaan tradisional yang biasanya hanya fokus pada satu dimensi jaringan, memungkinkan EfficientNet-B3 untuk mengalokasikan sumber daya komputasi secara lebih efektif dan mencapai keseimbangan yang lebih baik antara akurasi dan efisiensi.

Model EfficientNet-B3 dibangun di atas arsitektur dasar yang menggunakan blok *Mobile Inverted Bottleneck Convolution* (MBConv). Blok ini dikenal karena efisiensinya dalam melakukan operasi konvolusi dengan jumlah parameter dan komputasi yang lebih sedikit dibandingkan dengan blok konvolusi standar. Selain itu, beberapa blok MBConv dalam EfficientNet-B3 dilengkapi dengan modul *Squeeze-and-Excitation* (SE), yang memungkinkan jaringan untuk mempelajari kepentingan relatif dari berbagai saluran fitur, sehingga meningkatkan kemampuan representasi model (Ba Alawi & Bozkurt, 2023). Kombinasi dari blok MBConv dan pendekatan penskalaan gabungan memungkinkan EfficientNet-B3 untuk mencapai

kinerja yang baik dengan sumber daya yang lebih terbatas. Arsitektur EfficientNet-B3 dapat dilihat pada gambar 2.6.

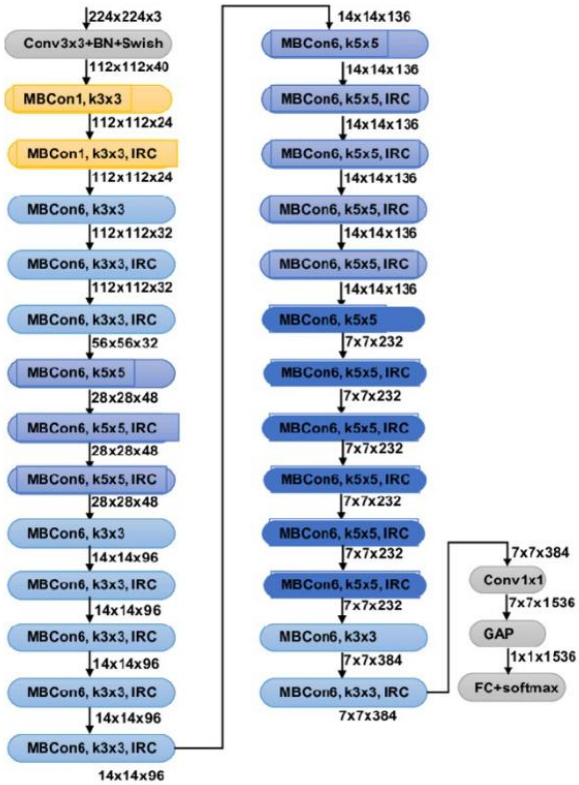

Gambar 2. 6 Arsitektur EffcientNetB3

Gambar 2.6 merupakan arsitektur EfficientNet-B3, alur pemrosesan dimulai dengan input gambar 224x224 RGB yang melewati lapisan konvolusi awal (Conv3x3) diikuti oleh *Batch Normalization* dan aktivasi *Swish*. Ini menghasilkan fitur peta awal dengan dimensi 112x112 dan 40 saluran. Selanjutnya, jaringan terdiri dari serangkaian tahapan yang berisi tumpukan blok MBConv dengan konfigurasi yang bervariasi dalam ukuran kernel (3x3 atau 5x5) dan faktor ekspansi. Perhatikan bagaimana resolusi spasial fitur peta secara bertahap berkurang sementara jumlah saluran meningkat seiring dengan kedalaman jaringan, mencerminkan hierarki fitur yang dipelajari oleh model. Keberadaan *Inverted*

Residual Connection (IRC) dalam beberapa blok MBConv juga terlihat, yang berperan penting dalam memfasilitasi pelatihan jaringan yang lebih dalam dan mencegah masalah vanishing gradient.

Di bagian akhir arsitektur, setelah melalui serangkaian blok MBConv, fitur peta dengan resolusi 7x7 dan 384 saluran diproses oleh lapisan konvolusi 1x1 (Conv1x1) untuk memperluas jumlah saluran menjadi 1536. Operasi *Global Average Pooling* (GAP) kemudian mereduksi dimensi spasial menjadi vektor 1x1536. Akhirnya, vektor fitur ini diumpankan ke lapisan *Fully Connected* (FC) yang diikuti oleh fungsi aktivasi *softmax* untuk menghasilkan probabilitas kelas. Konfigurasi arsitektur yang spesifik ini, dengan variasi dalam jenis blok MBConv dan jumlah filternya di setiap tahapan, adalah hasil dari proses pencarian arsitektur yang dirancang untuk mengoptimalkan kinerja dan efisiensi EfficientNet-B3.

2.2.8 Roboflow

Roboflow adalah *platform* berbasis web yang mendukung pengembangan aplikasi *computer vision*, khususnya dalam pengelolaan dataset untuk deteksi objek. *Platform* ini menyediakan fitur anotasi objek menggunakan *bounding box*, pra pemrosesan data seperti konversi *grayscale*, serta augmentasi untuk memperkaya variasi dataset. Roboflow mempermudah proses pengelolaan dan berbagi dataset secara kolaboratif, yang merupakan langkah penting dalam membangun model berbasis *deep learning*. Selain itu, platform ini membantu mengatasi tantangan dalam tahap akuisisi data, memastikan dataset yang digunakan berkualitas tinggi dan relevan. Dengan integrasi *pipeline* untuk anotasi, augmentasi, dan pelatihan

model, Roboflow menjadi alat yang efektif dalam mendukung penelitian dan pengembangan sistem deteksi objek (Hayati et al., 2023).

2.2.9 Metode Kramer

Metode Kramer adalah pendekatan yang digunakan untuk menilai derajat penyakit kuning pada bayi dengan mengamati perubahan warna kulit akibat peningkatan kadar bilirubin dalam darah. Dikembangkan oleh Dr. H. Kramer pada tahun 1960-an, metode ini membagi derajat ikterus menjadi beberapa kategori berdasarkan lokasi dan intensitas warna kuning yang terlihat pada kulit. Penilaian visual ini didasarkan pada prinsip bahwa peningkatan kadar bilirubin akan menyebabkan perubahan warna yang dapat diamati secara klinis (Kramer, 1969). Metode Kramer membagi tubuh bayi menjadi 5 bagian yang dapat dilihat pada gambar 2.7.

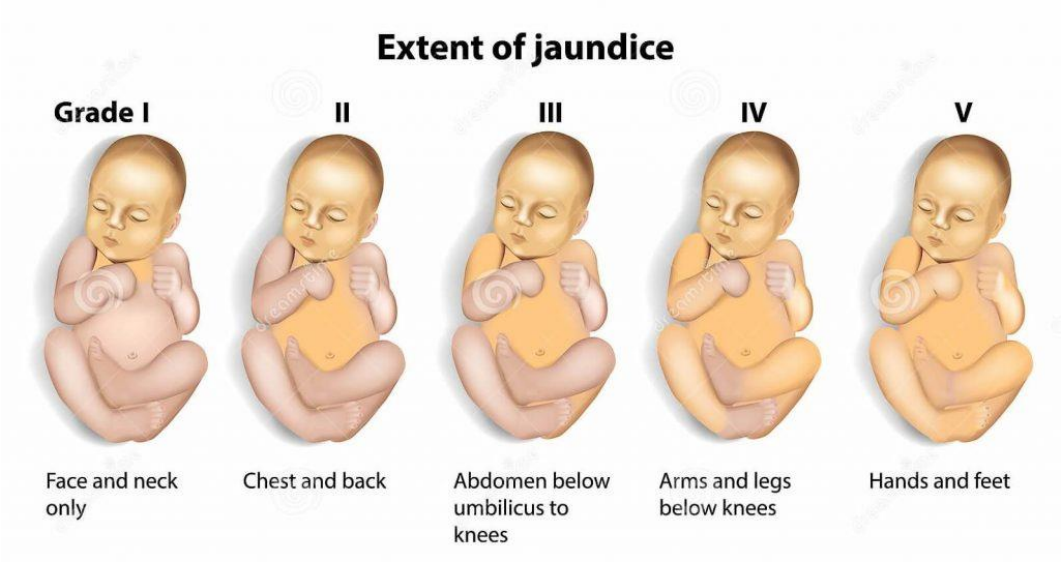

Gambar 2. 7 Tingkat Penyakit Kuning berdasarkan Metode Kramer

Gambar 2.7 merupakan tingkat penyakit kuning berdasarkan metode Kramer, Zona 1 mencakup kepala dan leher (bilirubin <5 mg/dL), Zona 2 meliputi

batang tubuh hingga pusar (bilirubin 5–10 mg/dL), Zona 3 mencakup area tubuh dari pusar hingga lutut (bilirubin 10-12 mg/dL), Zona 4 meliputi lengan dan tungkai bawah (bilirubin 12-15 mg/dL), dan Zona 5 mencakup telapak tangan dan kaki (bilirubin >15 mg/dL). Perubahan warna kuning yang muncul di zona tubuh tertentu memberikan gambaran awal tingkat keparahan penyakit.

Penyakit kuning berdasarkan metode kramer dibagi menjadi 5 *grade*, dimana setiap *gradenya* mempunyai rekomendasi penanganan berbeda, apabila bayi ada di *grade* 1 rekomendasi penanganannya yaitu pemberian ASI yang kuat, grade 2 rekomendasi penanganannya yaitu jemur dibawah sinar matahari, *grade* 3 bayi memerlukan fototerapi, apabila ada di grade 4 bayi memerlukan fototerapi yang intensif, dan apabila ada di grade 5 maka bayi harus menjalani transfusi tukar (Ramadhanty & Puspitasari, 2022).

BAB III

METODOLOGI PENELITIAN

3.1 Peta Jalan (*Roadmap*) Penelitian

Penelitian ini tetap selaras dengan *roadmap* penelitian Universitas Siliwangi dalam sub-bidang *Artificial Intelligence*. *Roadmap* penelitian tersebut dapat dilihat pada gambar 3.1.

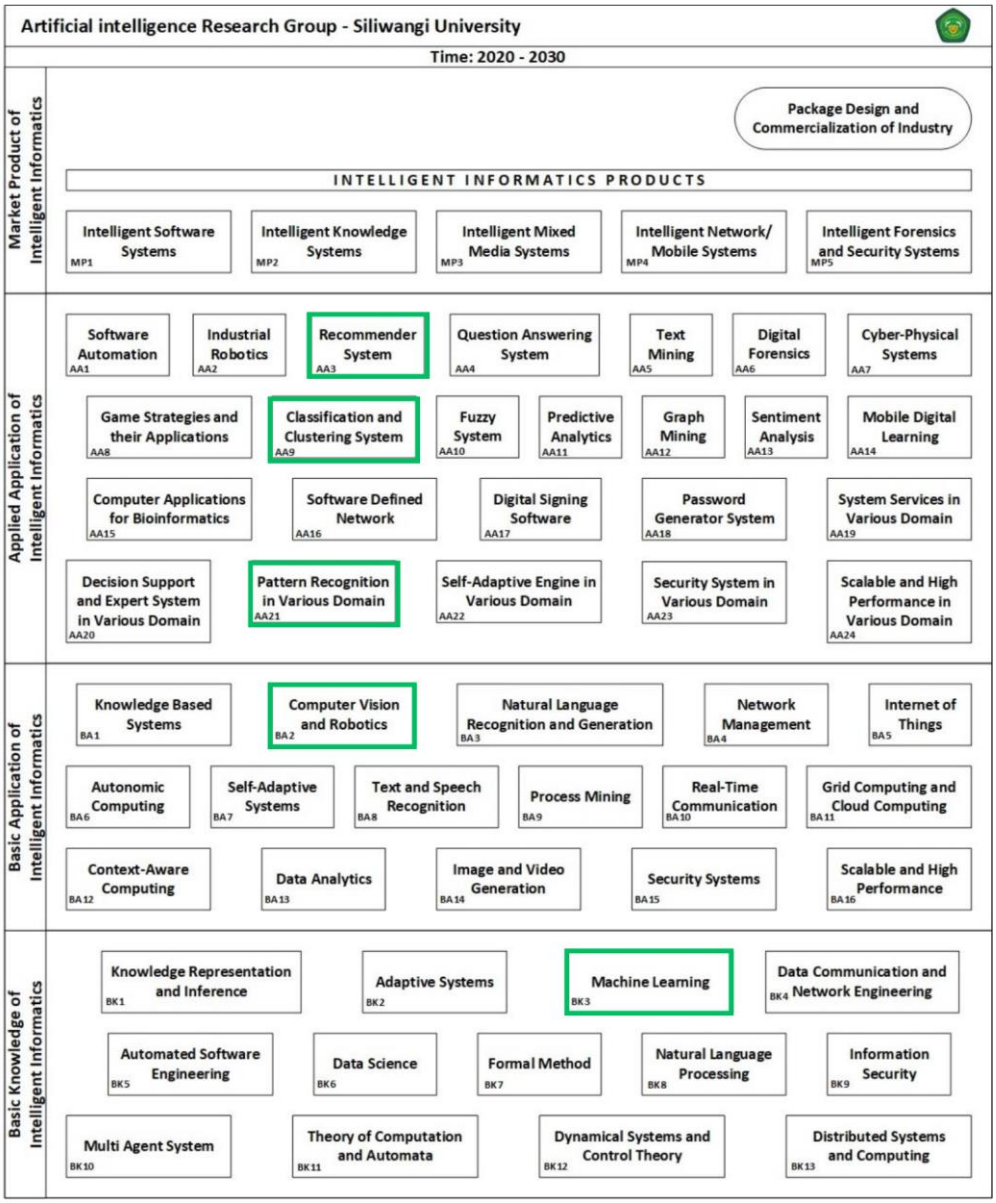

Gambar 3. 1 *Roadmap* Penelitian *Artificial Intelligence Research Group*

Gambar 3.1 menunjukkan *roadmap* penelitian ini yang terintegrasi dengan beberapa kategori dalam *Artificial Intelligence Research Group* Universitas Siliwangi. Penelitian ini berada pada persimpangan berbagai sub-bidang, yaitu *Computer Vision and Robotics* dengan memanfaatkan pengolahan citra digital untuk menganalisis pola warna kulit bayi sebagai indikator tingkat keparahan penyakit kuning, *Pattern Recognition in Various Domains* yang berfokus pada pengenalan pola citra kulit untuk mendeteksi hiperbilirubinemia secara non-invasif, serta *Classification and Clustering Systems* melalui penerapan algoritma CNN untuk mengklasifikasikan tingkat keparahan penyakit. Selain itu, penelitian ini relevan dengan *Recommender System* karena memberikan rekomendasi langkah penanganan berdasarkan hasil klasifikasi, dan berbasis *Machine Learning* dengan menggunakan CNN sebagai pendekatan utama. Integrasi ini mencerminkan kontribusi penelitian terhadap pengembangan sistem cerdas berbasis analisis visual untuk mendukung diagnosis dan rekomendasi penanganan yang akurat.

3.2 Tahapan Penelitian

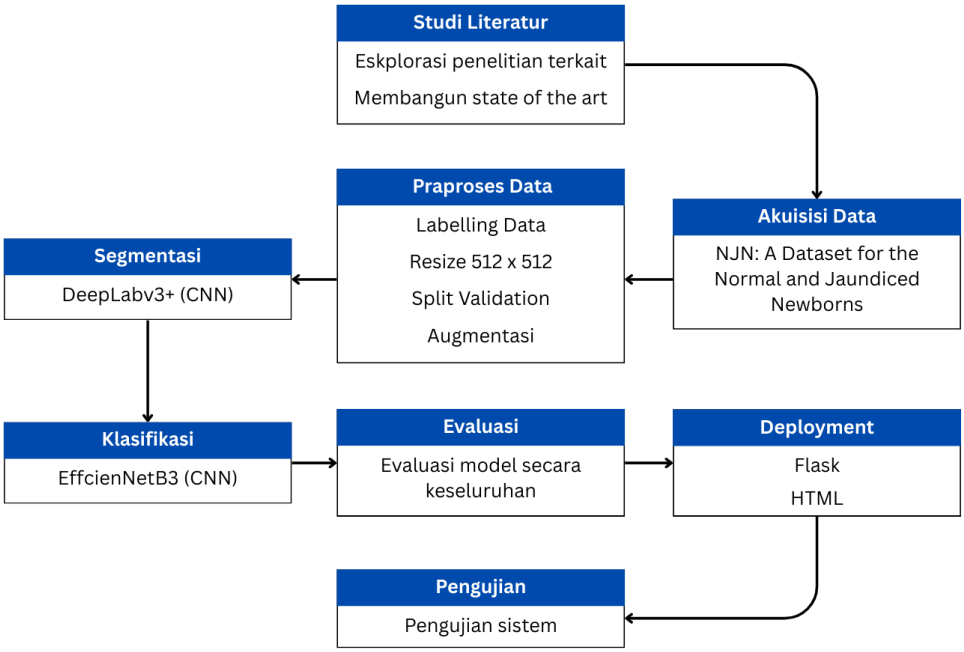

Gambar 3. 2 Tahapan Penelitian

Gambar 3.2 menunjukkan tahapan penelitian yang terdiri dari beberapa langkah yang dilakukan secara sistematis untuk mencapai tujuan deteksi penyakit kuning pada bayi menggunakan model CNN. Tahapan penelitian tersebut dijelaskan sebagai berikut:

3.2.1 Studi Literatur

Studi literatur dilakukan dengan mengeksplorasi berbagai jurnal penelitian dan karya terkait. Proses pencarian selanjutnya berfokus pada pemilihan *technical paper* yang terindeks dan relevan, sehingga dapat membangun *state of the art* yang mendukung berjalannya penelitian ini.

3.2.2 Akuisisi Data

Data yang digunakan pada penelitian ini berasal dari NJN: *A Dataset for the Normal and Jaundiced Newborns*, yang mencakup 670 citra bayi dengan resolusi

1000 × 1000 piksel dalam format JPG. Dataset ini terdiri atas 560 citra bayi normal dan 200 citra bayi dengan kondisi penyakit kuning (*jaundice*). Data tersebut akan dimanfaatkan untuk melatih dan menguji model *Convolutional Neural Network* (CNN), dengan tujuan mengembangkan sistem yang mampu mendeteksi dan mengklasifikasikan tingkat keparahan penyakit kuning secara akurat dan efisien.

3.2.3 Pra Proses Data

Pada tahapan pra proses data ini melalui beberapa langkah penting untuk memastikan kualitas dataset sebelum digunakan dalam pelatihan model. Langkah pertama adalah *labeling*, di mana data dilakukan anotasi menggunakan RoboFlow dengan menandai bagian kulit tubuh bayi yang terlihat, seperti wajah, perut, paha, lengan/kaki, dan telapak tangan/kaki, sementara area yang tertutup pakaian atau objek lain diabaikan. Data yang diberi label hanya 300 data, 150 data bayi normal, dan 150 data bayi *jaundice*. Setelah proses anotasi selesai, gambar diubah ukurannya menjadi resolusi 512x512 piksel agar lebih ringan dan mudah diproses. Dataset kemudian dibagi menjadi tiga bagian menggunakan skema *split validation* dengan proporsi 60% (180 gambar) untuk pelatihan, 30% (90 gambar) untuk validasi, dan 10% (30 gambar) untuk pengujian. Pada data pelatihan, augmentasi diterapkan menggunakan teknik seperti *flip horizontal*, *rotation*, serta penyesuaian gradasi warna, sehingga jumlah total data setelah augmentasi menjadi 3.024 gambar.

3.2.4 Segmentasi

Pada tahap pemodelan segmentasi, penelitian ini mengimplementasikan arsitektur DeepLabv3+ berbasis *Convolutional Neural Network* (CNN) untuk

mendeteksi dan menandai area kulit bayi yang relevan berdasarkan hasil anotasi. Model DeepLabv3+ dipilih karena kemampuannya yang unggul dalam melakukan *semantic segmentation* dengan memanfaatkan *atrous convolution* dan *Atrous Spatial Pyramid Pooling* (ASPP). Teknik ini memungkinkan model untuk menangkap informasi kontekstual multi-skala tanpa mengurangi resolusi spasial, yang sangat penting untuk segmentasi area kulit bayi secara akurat. Dengan memanfaatkan DeepLabv3+, setiap bagian tubuh bayi yang relevan, seperti wajah, perut, paha, lengan/kaki, dan telapak tangan/kaki, dapat disegmentasi dengan tingkat presisi yang tinggi. Segmentasi yang akurat ini menjadi pondasi penting untuk analisis warna kulit lebih lanjut dalam proses deteksi penyakit kuning yang optimal.

3.2.5 Klasifikasi

Klasifikasi dalam penelitian ini menggunakan arsitektur *EfficientNetB3*, sebuah model berbasis *Convolutional Neural Network* (CNN) yang dikenal ringan dan efisien. Pemilihan model ini didasarkan pada kemampuan *EfficientNetB3* untuk mencapai performa tinggi dalam tugas klasifikasi dengan parameter yang lebih kecil dibandingkan arsitektur lain, sehingga ideal untuk diterapkan pada sistem berbasis *web* dengan keterbatasan komputasi. Model ini mengoptimalkan skala kedalaman, lebar, dan resolusi jaringan untuk menghasilkan akurasi deteksi yang baik tanpa membebani sumber daya. Melalui dataset yang telah melalui tahap segemntasi, model ini akan digunakan untuk mengklasifikasikan tingkat keparahan penyakit kuning berdasarkan citra kulit bayi dengan akurasi tinggi.

3.2.6 Evaluasi

Evaluasi model dilakukan untuk menilai performa segmentasi menggunakan arsitektur DeepLabv3+ berbasis CNN dan klasifikasi dengan arsitektur *EfficientNetB3* berbasis CNN pada deteksi penyakit kuning pada bayi. model dievaluasi menggunakan metrik akurasi, *precision*, *recall*, dan *F1-score* untuk memastikan konsistensi dalam mengklasifikasikan citra kulit bayi ke dalam kategori *jaundice* atau normal. Selain itu, analisis *confusion matrix* juga dilakukan untuk mengidentifikasi jenis-jenis kesalahan prediksi yang mungkin terjadi. Hasil evaluasi ini memberikan dasar yang kuat untuk menilai keandalan algoritma CNN dalam mendeteksi dan mengklasifikasikan penyakit kuning pada bayi berdasarkan citra kulit.

3.2.7 Deployment

Tahap *deployment* dilakukan untuk mengintegrasikan model klasifikasi ke dalam aplikasi *web* yang dapat digunakan secara langsung oleh pengguna. *Backend* aplikasi menggunakan *framework Flask*, yang berfungsi untuk mengelola input dari pengguna, menjalankan prediksi menggunakan model klasifikasi, dan menampilkan hasil prediksi beserta rekomendasi penanganannya. *Framework* ini dipilih karena ringan, fleksibel, dan mudah diintegrasikan dengan model *machine learning* berbasis *Python*. Antarmuka pengguna dirancang menggunakan HTML, sehingga menghasilkan tampilan yang sederhana dan *user-friendly*. Melalui antarmuka ini, pengguna dapat mengunggah gambar bayi untuk diproses oleh sistem, yang kemudian akan memberikan prediksi tingkat keparahan penyakit kuning secara cepat dan akurat. *Deployment* ini memungkinkan sistem deteksi

berbasis CNN dapat diakses secara luas oleh tenaga medis atau orang tua, untuk mendukung pengambilan keputusan klinis dengan efisien.

3.2.8 Pengujian

Pengujian dilakukan untuk memastikan bahwa sistem klasifikasi tingkat keparahan penyakit kuning pada bayi dapat berfungsi dengan akurat dan andal setelah di-*deploy* pada aplikasi berbasis *web*. Proses pengujian melibatkan pengunggahan citra bayi oleh pengguna, yang kemudian diproses oleh model CNN untuk menentukan tingkat keparahan penyakit kuning sesuai dengan metode Kramer, menghasilkan klasifikasi dalam *grade* 1 hingga 5. Pengujian ini bertujuan untuk memastikan bahwa sistem dapat memberikan hasil yang konsisten, relevan, dan sesuai dengan kebutuhan pengguna, serta mendukung pengambilan keputusan dalam penanganan medis lebih lanjut.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Akuisisi Data

Dataset yang digunakan pada penelitian ini adalah NJN*: A Dataset for the Normal and Jaundiced Newborns* diperoleh dari situs Zenodo. Dataset ini berisi 670 citra digital dengan resolusi 1000 x 1000, dan dibagi 2 kelas yaitu Normal dengan jumlah 560 citra digital, kemudian *Jaundice* berjumlah 200 citra digital. Hasil akuisisi data dapat dilihat pada gambar 4.1.

Gambar 4. 1 Akuisisi Data

4.2 Pra Proses Data

Pra proses dilakukan untuk mempersiapkan data gambar kulit bayi agar siap digunakan dalam model deteksi penyakit kuning menggunakan CNN. Langkah-langkahnya meliputi *labeling*, *resize* gambar, pembagian data menjadi set latih, validasi, dan uji, dan untuk memastikan model dapat dilatih dan dievaluasi dengan optimal.

4.2.1 Labelling

Proses pelabelan dilakukan menggunakan Roboflow dengan memberikan anotasi berupa *mask* pada setiap bagian tubuh bayi yang terekspos kulit. Anotasi ini hanya dilakukan pada area kulit bayi, sementara bagian tubuh yang tertutup pakaian atau objek lain diabaikan. Pembagian anotasi mencakup lima bagian tubuh, yaitu wajah, perut, paha, lengan/kaki, dan telapak tangan/kaki, untuk memastikan segmentasi yang akurat pada setiap area yang relevan. Hasil *labelling* dapat dilihat pada gambar 4.2.

Gambar 4. 2 *Labelling*

4.2.2 *Resize* Gambar

Gambar dengan resolusi awal 1000 x 1000 piksel diubah ukurannya menjadi 512 x 512 piksel untuk mengurangi beban komputasi, sehingga proses pelatihan model menjadi lebih ringan dan efisien. Proses resize gambar dapat dilihat pada gambar 4.3.

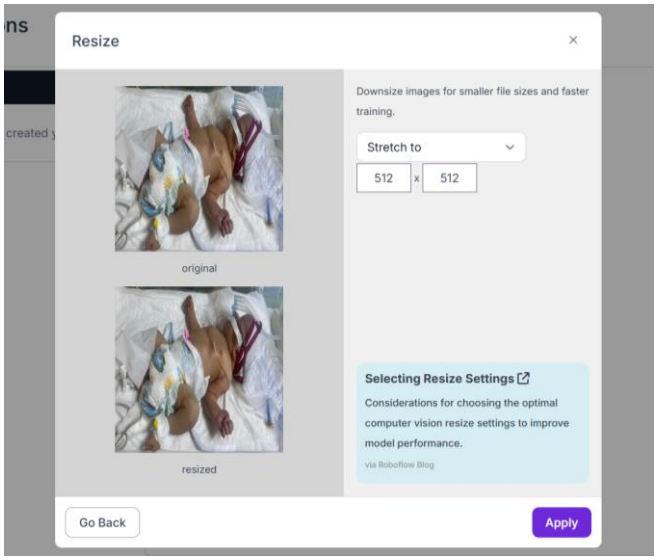

Gambar 4. 3 *Resize* Gambar

4.2.3 Split Validation

Dataset dibagi menggunakan skema *split validation* dengan proporsi 60% (180 gambar) untuk pelatihan, 30% (90 gambar) untuk validasi, dan 10% (30 gambar) untuk pengujian. Pembagian ini bertujuan untuk memastikan model dapat dilatih secara optimal, divalidasi untuk menghindari *overfitting*, dan diuji untuk mengevaluasi performa secara menyeluruh. Proses *split validation* dapat dilihat pada gambar 4.4.

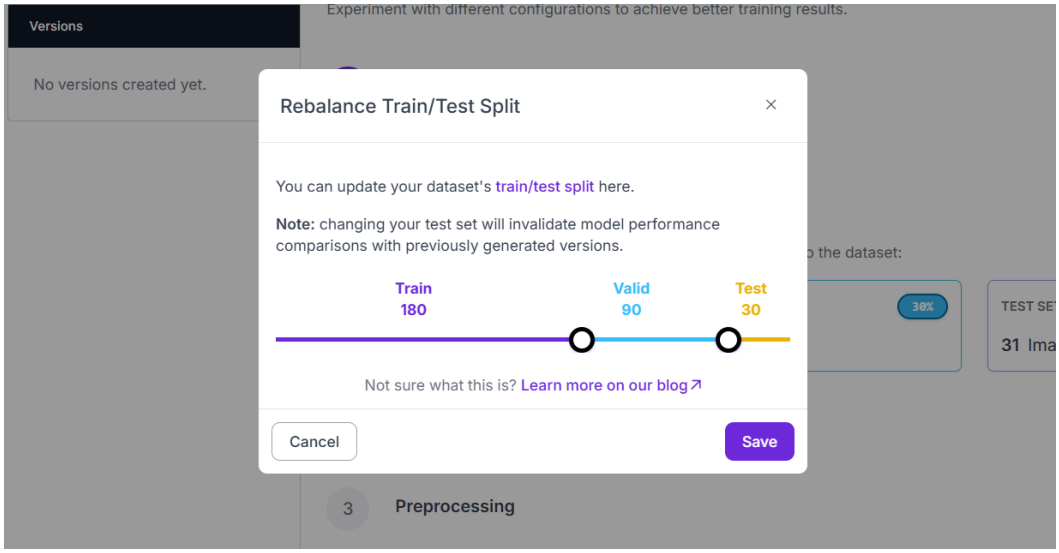

Gambar 4. 4 ***Split Validation***

4.2.4 Augmentasi

Proses augmentasi dilakukan untuk meningkatkan variasi dataset menggunakan berbagai transformasi, dengan *flip horizontal*, rotasi 90° (searah dan berlawanan arah jarum jam), rotasi acak antara -15° hingga +15°, dan *shear horizontal* serta vertial hingga ±10°. Selain itu, augmentasi mencakup konversi sebagian gambar menjadi *grayscale* (15%), penyesuaian hue antara -15° hingga +15°, saturasi antara -25% hingga +25%, brightness antara -15% hingga +15%, serta exposure antara -10% hingga +10%. Teknik lainnya meliputi penambahan blur hingga 2,5 piksel dan *noise* hingga 0,89% piksel. Setelah proses augmentasi, jumlah total data meningkat menjadi 3.024 gambar, yang siap digunakan dalam pelatihan model. Proses Augmentasi dapat dilihat pada gambar 4.5.

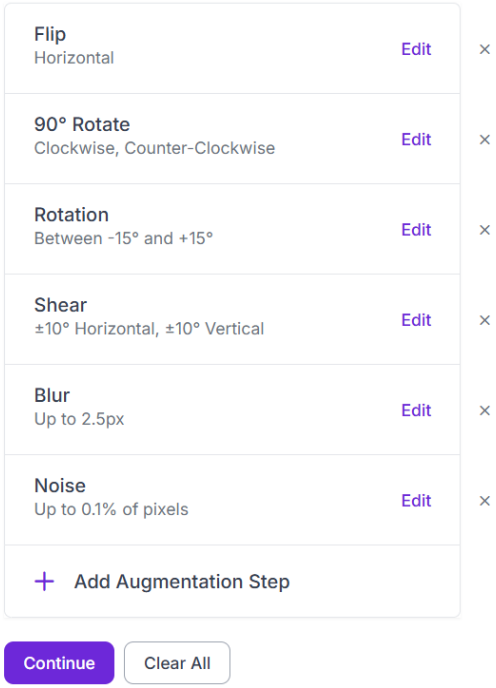

Gambar 4. 5 Augmentasi

4.3 Segmentasi

Segmentasi dilakukan menggunakan arsitektur CNN DeepLabv3+, sebuah model mutakhir yang dirancang untuk tugas deteksi dan segmentasi objek. Proses ini dimulai dengan pengunduhan dataset "*neonatal-skin-detection*" dari *platform* Roboflow, menggunakan API untuk mendapatkan versi dataset yang relevan dalam format kompatibel dengan DeepLabv3. Dataset ini dirancang secara spesifik untuk mendukung segmentasi area kulit pada citra bayi.

4.3.1 Buat Model Segmentasi

Model segmentasi dibuat menggunakan arsitektur DeepLabv3+ dengan backbone ResNet101 sebagai encoder untuk ekstraksi fitur. Model ini dirancang untuk menghasilkan *mask* segmentasi dengan resolusi tinggi yang sesuai dengan ukuran gambar input (512x512 piksel). ResNet101 memberikan kemampuan untuk

mengenali pola visual kompleks, sedangkan bagian decoder model meningkatkan resolusi prediksi agar sesuai dengan kebutuhan segmentasi.

```
from tensorflow.keras.applications import ResNet101
def   create_deeplabv3plus_model(input_shape=(512,   512,   3),
num_classes=2):
    base_model          =          ResNet101(weights='imagenet',
include_top=False, input_shape=input_shape)
    # Tambahkan layer segmentasi
    return model
```

4.3.2 Pelatihan Model

Model dilatih menggunakan dataset yang telah diproses dengan fungsi *loss* berbasis *Dice Loss* untuk menangani ketidakseimbangan kelas pada segmentasi. Pelatihan dilakukan selama 50 *epoch*, dengan callback seperti *EarlyStopping* untuk menghentikan pelatihan ketika validasi *loss* tidak membaik, serta ReduceLROnPlateau untuk menurunkan learning rate secara dinamis jika model mengalami stagnasi. Strategi ini berhasil mengoptimalkan proses pelatihan, mencegah *overfitting*, dan memastikan konvergensi yang stabil.

```
from ultralytics import YOLO
from tensorflow.keras.callbacks import EarlyStopping,
ReduceLROnPlateau
early_stopping = EarlyStopping(monitor="val_loss", patience=10,
restore_best_weights=True)
reduce_lr = ReduceLROnPlateau(monitor='val_loss', factor=0.1,
patience=5)
model.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=0.001),
    loss=dice_loss,  # Menggunakan fungsi loss kustom
    metrics=["accuracy"])
history = model.fit(
    train_generator,
```

```
    validation_data=valid_generator,
    epochs=50,
    callbacks=[early_stopping, reduce_lr])
```

Hasil dari pemodelan segmentasi ini adalah area kulit bayi yang tersegmentasi secara akurat, yang kemudian digunakan sebagai input untuk model klasifikasi berbasis CNN. Segmentasi yang andal sangat penting untuk mengurangi *noise* pada data dan meningkatkan akurasi klasifikasi tingkat keparahan penyakit kuning.

4.4 Klasifikasi

Pada tahap ini dilakukan klasifikasi berbasis Convolutional Neural Network (CNN) menggunakan arsitektur EfficientNetB3 untuk mendeteksi gejala penyakit kuning (*jaundice*) pada bayi. Model ini bertujuan mengklasifikasikan citra ke dalam dua kelas, yaitu “Normal” dan “Jaundice”, serta klasifikasi berdasarkan *grade*.

Sebelum melakukan klasifikasi, data hasil segmentasi di *crop* per bagian tubuh untuk meningkatkan fokus model pada area spesifik yang relevan dengan deteksi penyakit kuning. Data setelah *cropping* menghasilkan jumlah data kelas paha yaitu (jaundice 2009, normal 1905), perut (jaundice 1517, normal 1596), telapak tangan (jaundice 1106, normal 1259), wajah (jaundice 1223, normal 1562), dan lengan (jaundice 3596, normal 3869). *Cropping* data ini memastikan model mempelajari secara spesifik area tubuh yang berbeda, dan meningkatkan akurasi klasifikasi.

4.4.1 Load Data

Pertama adalah load data terlebih dahulu, load data yang ditampilkan yaitu untuk kelas wajah, untuk kelas yang lainnya dilakukan satu per satu secara bergantian.

```
data_dir = '/content/drive/MyDrive/wajah'
categories = ['Normal', 'Jaundice']
img_size = 300
val_split = 0.15
test_split = 0.1
```

Selain *import* data dengan dua kategori (normal dan *jaundice*), semua gambar di data tersebut di *resize* ke 300 x 300. Kemudian split data ke 15% untuk validasi dan 10% untuk tes.

4.4.2 Inisiasi *Load* dan *Split Data*

Tahapan inisiasi dan split data ini mengimplementasikan *pipeline* pengolahan gambar yang efisien dengan pengelolaan memori optimal. Proses dimulai dengan mengumpulkan *path* gambar dan label secara iteratif tanpa memuat seluruh gambar ke dalam memori. Setiap gambar diambil dari direktori kategori tertentu dan dipasangkan dengan indeks labelnya. Untuk menjaga distribusi kelas, dataset dibagi menggunakan stratified splitting. Tahap pertama memisahkan 10% data sebagai test set, sedangkan tahap kedua membagi sisa data menjadi train set (75%) dan validation set (15%). Pendekatan ini memastikan proporsi kelas tetap konsisten di setiap subset data.

```
# Split test set dulu
trainval_paths, test_paths, trainval_labels, test_labels =
train_test_split(
```

```
    image_paths, labels, test_size=test_split, stratify=labels,
random_state=42
)
# Loader function hemat RAM
def load_images(paths, labels, desc="Loading images"):
    X = []
    y = []
    for img_path, label in tqdm(zip(paths, labels),
total=len(paths), desc=desc):
        try:
            img = cv2.imread(img_path)
            if img is None:
                print(f"⚠ Skip broken image: {img_path}")
                continue
            img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)
            img = cv2.resize(img, (img_size, img_size))
            img = img.astype(np.float16) / 255.0  # float16
lebih hemat RAM
            X.append(img)
            y.append(label)
        except Exception as e:
            print(f"⚠ Error: {img_path}, {e}")
    return np.array(X, dtype=np.float16), np.array(y)
```

Loading gambar dilakukan secara *on-demand* menggunakan fungsi *load_images* dengan tiga teknik penghematan memori: pembacaan *batch* dengan tqdm untuk memantau progres, konversi warna dari BGR ke RGB dan *resize* ke dimensi seragam, serta reduksi presisi piksel menjadi float16 untuk mengurangi konsumsi memori. Gambar-gambar rusak atau *error* dilewati, sementara gambar valid dinormalisasi ke rentang [0,1] dan dikembalikan sebagai array NumPy.

4.4.3 Buat Model *EfficientNetB3*

Membangun model klasifikasi biner berbasis *transfer learning* dengan arsitektur *EfficientNetB3*. Model dasar (*base model*) diambil dengan bobot pra-latih (*pre-trained weights*) dari *ImageNet*, kemudian dibekukan (*freeze*) agar tidak terlatih ulang pada tahap awal. Lapisan *output* dasar dihubungkan dengan beberapa lapisan tambahan, termasuk GlobalAveragePooling2D untuk reduksi dimensi, dua lapisan *Dense* dengan aktivasi ReLU (128 dan 64 neuron) yang disertai *BatchNormalization* dan *Dropout* (rate=0.3) untuk regularisasi, serta lapisan output tunggal dengan aktivasi sigmoid untuk klasifikasi biner.

```
base_model = EfficientNetB3(include_top=False,
weights='imagenet', input_shape=(img_size, img_size, 3))
base_model.trainable = False  # Freeze awal

x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dropout(0.3)(x)
x = Dense(128, activation='relu')(x)
x = BatchNormalization()(x)
x = Dropout(0.3)(x)
x = Dense(64, activation='relu')(x)
x = BatchNormalization()(x)
x = Dropout(0.3)(x)
output = Dense(1, activation='sigmoid')(x)

model = Model(inputs=base_model.input, outputs=output)

model.compile(optimizer=Adam(learning_rate=1e-4),
loss='binary_crossentropy', metrics=['accuracy'])
model.summary()
```

Model dikompilasi menggunakan *optimizer Adam* dengan *learning rate* 1e-4, fungsi *loss binary_crossentropy*, dan metrik akurasi. Pendekatan ini memanfaatkan fitur hierarkis *EfficientNet* yang sudah terlatih sambil menambahkan lapisan khusus untuk tugas klasifikasi baru, dengan teknik *dropout* dan *batch normalization* untuk mencegah *overfitting*.

4.4.4 Training Phase 1

Fase pelatihan awal (Phase 1) dengan model dasar (*base model*) dalam keadaan dibekukan (*frozen*). Proses *training* dilakukan selama 10 *epoch* menggunakan *batch size* 64, dengan memanfaatkan data latih (*X_train*, *y_train*) dan data validasi (*X_val*, *y_val*) untuk memantau performa model.

```
print("\n🚀 Training Phase 1 (Base Model Frozen)...")
history1 = model.fit(
    X_train, y_train,
    validation_data=(X_val, y_val),
    epochs=10,
    batch_size=16,
    callbacks=[early_stopping, checkpoint],
    verbose=1)
```

Callback checkpoint digunakan untuk menyimpan bobot model terbaik selama pelatihan. Output pelatihan ditampilkan secara lengkap (*verbose=1*) untuk memantau metrik akurasi dan *loss* pada setiap *epoch*. Fase ini bertujuan untuk melatih hanya lapisan tambahan (*fully connected layers*) sambil mempertahankan fitur yang sudah dipelajari oleh *EfficientNetB3*, sehingga model dapat beradaptasi secara bertahap dengan data baru tanpa merusak representasi fitur yang sudah ada.

4.4.5 Training Phase 2

Pada *training phase* 2 melakukan *fine-tuning* model dengan membuka pembekuan (*unfreeze*) seluruh lapisan pada *base_model (EfficientNetB3)* untuk memungkinkan pelatihan menyeluruh. Setelah lapisan di-*unfreeze*, model dikompilasi ulang menggunakan *optimizer Adam* dengan *learning rate* lebih rendah untuk penyesuaian. Proses pelatihan fase kedua ini berjalan selama 30 *epoch* dengan *batch size* 64, tetap memanfaatkan *callback checkpoint* untuk menyimpan bobot terbaik dan memvalidasi performa menggunakan data validasi.

```
print("\n🔓 Unfreezing Base Model for Fine-tuning...")
base_model.trainable = True

model.compile(optimizer=Adam(learning_rate=1e-5),
loss='binary_crossentropy', metrics=['accuracy'])

print("\n🚀 Training Phase 2 (Fine-tuning)...")
history2 = model.fit(
    X_train, y_train,
    validation_data=(X_val, y_val),
    epochs=30,
    batch_size=16,
    callbacks=[early_stopping, checkpoint],
    verbose=1)
```

Fase *fine-tuning* ini bertujuan untuk mengoptimalkan seluruh arsitektur model, baik lapisan konvolusional *pre-trained* maupun lapisan klasifikasi tambahan, sehingga model dapat menyempurnakan fitur-fitur spesifik untuk tugas klasifikasi biner yang dihadapi. Penggunaan learning rate kecil membantu mencegah perubahan terlalu drastis pada bobot *pretrained*.

4.5 Evaluasi

Model dievaluasi dengan metrik akurasi, *precision*, *recall*, dan *f1-score*, metrik ini digunakan untuk mengukur sejauh mana model mampu mendeteksi dan memetakan bagian tubuh bayi secara akurat melalui *mask* segmentasi, dan memastikan kemampuan model dalam mengklasifikasikan tingkat keparahan penyakit kuning dari citra kulit bayi.

4.5.1 Model Segmentasi

Setelah proses segmentasi menggunakan DeepLabv3+ berbasis CNN pada dataset *neonatal*. Model berhasil mempelajari pola segmentasi dengan baik, menghasilkan nilai akurasi, *precision, recall, dan f1-score* yang tinggi. Berikut adalah evaluasi model segmentasi pada tabel 4.1.

Tabel 4. 1 Hasil Pemodelan Segmentasi

Kelas	Akurasi	Precision	Recall	F1-Score
Lengan/Kaki	76%	61,6%	81,4%	70,1%
Paha	80,6%	66,7%	84,2%	74,5%
Perut	95,6%	95 %	91,9%	93,4%
Telapak Tangan/Kaki	71,6%	72,1%	76,4%	74,2%
Wajah	78,2%	73,3%	85,9%	79,1%
Rata-rata	80, 4%	73,7%	84%	78,3%

Tabel 4.1 menunjukkan bahwa model DeepLabv3+ berbasis CNN untuk segmentasi memiliki kemampuan deteksi yang cukup baik dalam mendeteksi objek pada citra kulit bayi, dengan nilai tertinggi pada kelas "Perut" yaitu 95,6%, yang

menunjukkan akurasi tinggi dalam mendeteksi perubahan warna kulit yang jelas, seperti pada bayi dengan penyakit kuning. Secara keseluruhan, nilai rata-rata akurasi sebesar 80,4%, menunjukkan bahwa model DeepLabv3+ memiliki potensi yang baik dalam deteksi penyakit kuning. *Confusion Matrix* model segmentasi dapat dilihat pada gambar 4.6.

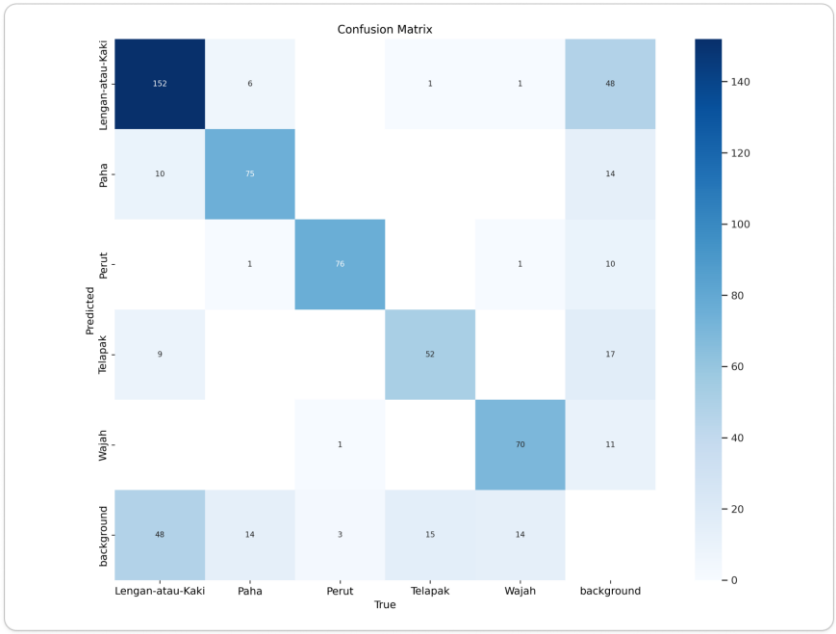

Gambar 4. 6 *Confusion Matrix* Model Segmentasi

Dalam gambar 4.6 model memiliki performa terbaik pada kelas "Lengan-atau-Kaki" dengan 152 prediksi benar. Secara keseluruhan, model menunjukkan performa cukup baik dalam membedakan antar kelas, namun masih terdapat kesalahan kecil.

4.5.2 Model Klasifikasi

Hasil evaluasi menunjukkan bahwa model CNN dengan arsitektur *EfficentNetB3* berhasil mencapai tingkat akurasi yang memadai dalam mengidentifikasi tingkat keparahan penyakit kuning, memberikan indikasi bahwa

metode ini dapat diandalkan dalam mendukung diagnosis. Hasil evaluasi dapat dilihat pada tabel 4.2.

Tabel 4. 2 Hasil Pemodelan Klasifikasi

Kelas	**Akurasi**	***Precision***	***Recall***	***F1-Score***
Lengan/Kaki	86,1 %	80,5 %	93,9 %	86,8 %
Paha	88,8 %	92,4 %	85,1 %	88,7 %
Perut	94,2 %	90,9 %	98 %	94,2 %
Telapak Tangan/Kaki	91,1 %	88,1 %	93,7 %	90,7 %
Wajah	83,9 %	82 %	81,3 %	81,7 %
Rata-rata	88,7 %	86,7 %	90,5 %	88,4 %

Tabel 4.2 merupakan hasil evaluasi pemodelan klasifikasi, secara keseluruhan, model menunjukkan performa yang baik dengan rata-rata akurasi 88,7%, precision 86,7%, recall 90,5%, dan F1-score 88,4%, di mana kelas "Perut" memiliki hasil evaluasi tertinggi. Berikut adalah *Confusion Matrix* pemodelan klasifikasi yang dapat dilihat pada gambar 4.7 sampai 4.11.

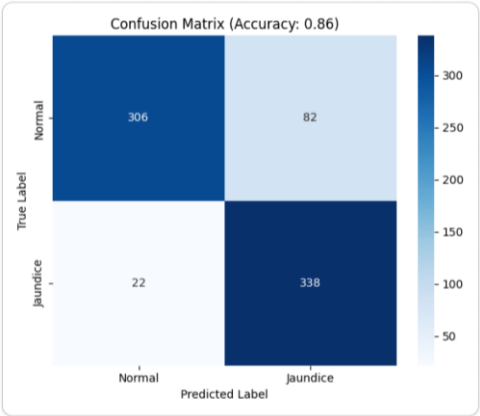

Gambar 4. 7 *Confusion Matrix* Lengan/Kaki

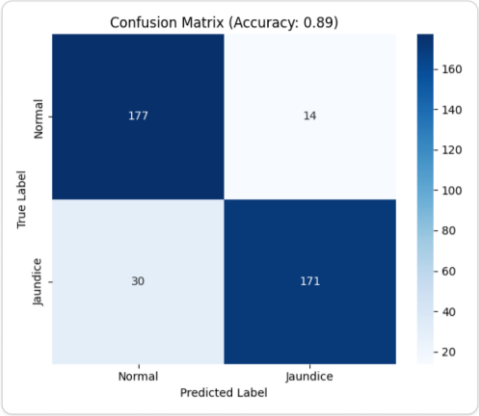

Gambar 4. 8 *Confusion Matrix* Paha

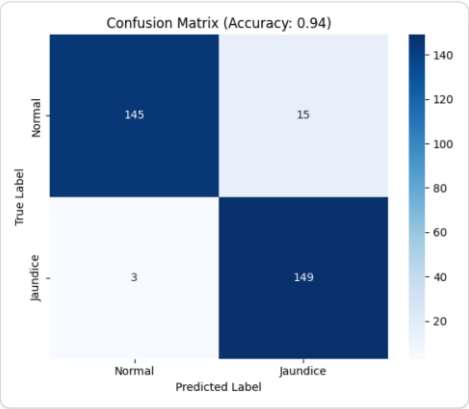

Gambar 4. 9 *Confusion Matrix* Perut

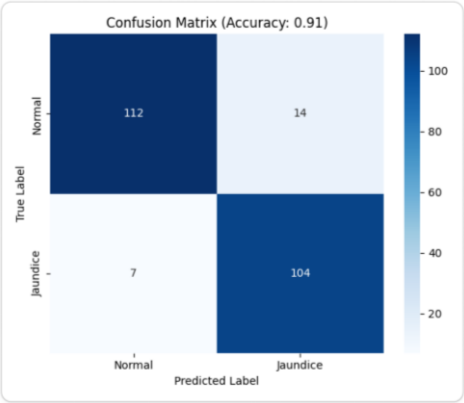

Gambar 4. 10 *Confusion Matrix* Telapak Tangan/Kaki

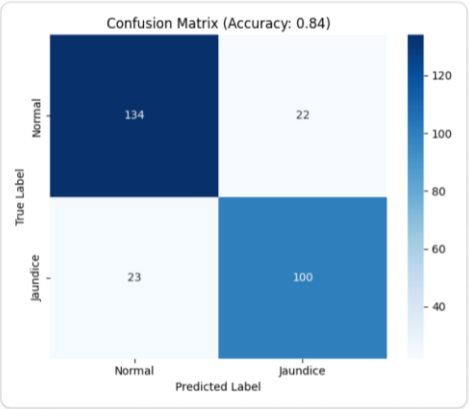

Gambar 4. 11 *Confusion Matrix* Wajah

Gambar 4.7 sampai 4.11 menampilkan *Confusion Matrix* yang mengevaluasi performa model klasifikasi biner. Secara umum, model-model tersebut menunjukkan akurasi yang baik, berkisar antara 83,9% hingga 94,2%, dengan distribusi kesalahan klasifikasi yang bervariasi antara *false positives* dan *false negatives*.

4.6 Deployment

Deployment aplikasi dilakukan menggunakan *framework Flask* sebagai *backend* dan HTML sebagai frontend. *Flask* digunakan untuk mengelola rute, menerima masukan citra dari pengguna, memprosesnya dengan model CNN, dan mengembalikan hasil klasifikasi tingkat keparahan penyakit kuning. Antarmuka aplikasi dirancang dengan HTML untuk memudahkan pengguna dalam mengunggah citra bayi serta melihat hasil prediksi. Hasil deployment dapat dilihat pada gambar 4.12.

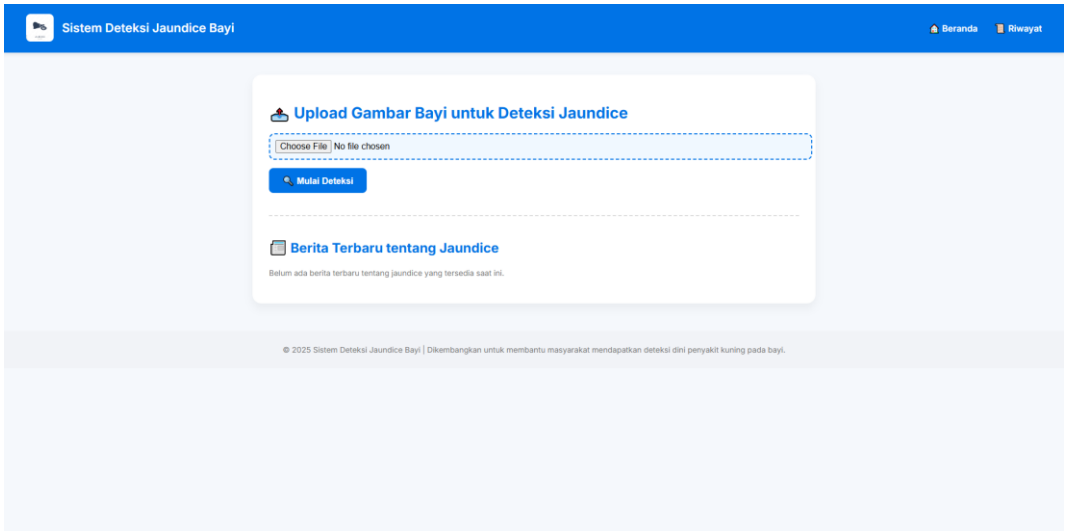

Gambar 4. 12 Hasil *Deployment*

Gambar 4.12 merupakan hasil *deployment*, menunjukkan bahwa aplikasi dapat berjalan dengan baik, di mana pengguna dapat mengakses aplikasi, mengunggah citra bayi, dan mendapatkan hasil klasifikasi tingkat keparahan secara *real-time*.

4.7 Pengujian

Pengujian dilakukan untuk memastikan bahwa aplikasi berbasis *web* dapat mengklasifikasikan tingkat keparahan penyakit kuning pada bayi secara akurat dan memberikan rekomendasi yang sesuai berdasarkan hasil klasifikasi. Proses pengujian melibatkan pengguna yang mengunggah citra bayi melalui antarmuka aplikasi. Citra tersebut kemudian diproses oleh model CNN yang telah diintegrasikan untuk menentukan tingkat keparahan penyakit kuning sesuai dengan metode Kramer (*grade* 1-5). Setelah itu, aplikasi menampilkan hasil klasifikasi disertai rekomendasi tindakan atau konsultasi medis berdasarkan tingkat keparahan yang terdeteksi. Berikut adalah hasil pengujian aplikasi yang bisa dilihat pada tabel 4.3.

Tabel 4. 3 Hasil Pengujian

Citra Uji	Label	Hasil Klasifikasi	Rekomendasi
	Jaundice	Grade 1	Pemberian ASI yang kuat kepada bayi

	Jaundice	Grade 2	Jemur dibawah sinar matahari
	Jaundice	Grade 4	Lakukan fototerapi yang intensif
	Jaundice	Grade 5	Bayi harus menjalani transfusi darah
	Normal	Normal	Bayi dalam kondisi normal

	Normal	Normal	Bayi dalam kondisi normal
	-	Tidak terdeteksi	Tidak ada bagian tubuh yang terdeteksi

Berdasarkan hasil pengujian, aplikasi secara keseluruhan berjalan dengan baik dan mampu mengklasifikasikan tingkat keparahan penyakit kuning pada bayi secara akurat ketika citra yang diunggah memiliki kualitas yang baik dan jelas, terutama pada area tubuh yang relevan untuk analisis, seperti kulit bayi. Namun, terdapat kendala ketika gambar yang diunggah oleh pengguna tidak jelas, seperti gambar yang buram, pencahayaan yang buruk, atau tidak menampilkan area tubuh bayi yang sesuai. Dalam kasus tersebut, aplikasi mengalami kesulitan mendeteksi citra dengan optimal, yang dapat menyebabkan hasil klasifikasi tidak akurat atau bahkan gagal memberikan hasil.

BAB V

KESIMPULAN DAN SARAN

Algoritma CNN terbukti efektif dalam mendeteksi penyakit kuning pada bayi dengan menggabungkan segmentasi citra digital dan klasifikasi tingkat keparahan. Seegmentasi citra digital menggunakan arsitektur CNN DeepLabv3 dan klasifikasi tingkat keparahan menggunakan arsitektur CNN EfficientNetb3, terbukti efektif dalam mendeteksi penyakit kuning pada bayi. Kinerja segmentasi yang baik dengan rata-rata akurasi 80,4% dan kemampuan klasifikasi tingkat keparahan yang tinggi mencapai 88,7% dengan metode Kramer sebagai parameter tingkat keparahan, serta memberikan rekomendasi penanganan yang sesuai berdasarkan tingkat keparahan penyakit kuning. Model ini membuktikan potensi besar dalam mendeteksi penyakit kuning secara non-invasif, mempercepat diagnosis, memberikan rekomendasi penanganan yang tepat, dan mengurangi risiko komplikasi serius seperti kernikterus.

Saran penelitian ke depannya adalah mengembangkan sistem deteksi penyakit kuning berbasis citra digital yang dapat diintegrasikan ke perangkat *mobile*, sehingga dapat digunakan secara praktis oleh tenaga medis atau orang tua di rumah. Selain itu, dataset yang digunakan perlu diperluas untuk mencakup variasi jenis kulit yang lebih beragam, tidak hanya bayi dengan kulit cerah, sehingga model dapat mengidentifikasi penyakit kuning dengan lebih akurat pada berbagai jenis kulit. Penelitian selanjutnya juga disarankan untuk mengeksplorasi algoritma lain selain CNN.

DAFTAR PUSTAKA

Ahmed, S., Abiduzzaman, M. D., Rajib, M. H., Rahaman, R., Hussain, S., Rashid, H. B., Wadud, A. H., & Amir-Ul-Haque Bhuiya, T. M. (2023). Human Skin Diseases Detection and Classification using CNN. *3rd International Conference on Electrical, Computer and Communication Engineering, ECCE 2023*. https://doi.org/10.1109/ECCE57851.2023.10101636

Akmal Dzulkifli, F., Yusoff Mashor, M., & Khalid, K. (2018). Methods for Determining Bilirubin Level in Neonatal Jaundice Screening and Monitoring: A Literature Review. In *Journal of Engineering Research and Education* (Vol. 10). https://www.researchgate.net/publication/329906308

Alsaedi, S. A. (2018). Transcutaneous Bilirubin Measurements Can Be Used to Measure Bilirubin Levels during Phototherapy. *International Journal of Pediatrics, 2018*, 1–5. https://doi.org/10.1155/2018/4856390

Ba Alawi, A. E., & Bozkurt, F. (2023). CNN-Based Colon Cancer Recognition Model. *2023 3rd International Conference on Emerging Smart Technologies and Applications (ESmarTA)*, 01–05. https://doi.org/10.1109/eSmarTA59349.2023.10293562

Bhagat, P. V, Raghuwanshi, M. M., & Bagde, A. D. (2024). Comparative Analysis of Classification of Neonatal Bilirubin by Using Various Machine Learning Approaches. *Cureus*. https://doi.org/10.7759/cureus.62019

Brits, H., Adendorff, J., Huisamen, D., Beukes, D., Botha, K., Herbst, H., & Joubert, G. (2018). The prevalence of neonatal jaundice and risk factors in healthy term neonates at National District Hospital in Bloemfontein. *AOSIS*. https://doi.org/10.4102/phcfm

Chen, L.-C., Papandreou, G., Kokkinos, I., Murphy, K., & Yuille, A. L. (2018). DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs. *IEEE Transactions on*

Pattern Analysis and Machine Intelligence, *40*(4), 834–848. https://doi.org/10.1109/TPAMI.2017.2699184

George, G., & S, A. (2024). Leveraging EfficientNet-B3 with Advanced Fine-Tuning for Precise Breast Cancer Classification. *2024 IEEE 16th International Conference on Computational Intelligence and Communication Networks (CICN)*, 938–944. https://doi.org/10.1109/CICN63059.2024.10847503

Gonzalez, R. C. ., & Woods, R. E. . (2008). *Digital Image Processing*. Prentice Hall.

Halder, M., Emrul Kabir, H. M., Mimi Rity, A., & Vowmik, A. (2022). An automated detection of Scabies skin disease Using Image Processing and CNN. *2022 4th International Conference on Sustainable Technologies for Industry 4.0, STI 2022*. https://doi.org/10.1109/STI56238.2022.10103250

Hayati, N. J., Singasatia, D., Muttaqin, M. R., Informatika, T., Tinggi, S., & Wastukancana, T. (2023). Object Tracking Menggunakan Algoritma You Only Look Once (YOLO)v8 untuk Menghitung Kendaraan. *KOMPUTA : Jurnal Ilmiah Komputer Dan Informatika*, *12*(2). https://universe.roboflow.com/

Hockenberry, M., Wilson, D., & Rodgers, C. (2015). *Essentials of Pediatric Nurisng*. Elsevier.

Imam Fathurrahman, Mahpuz, Muhammad Djamaluddin, Lalu Kerta Wijaya, & Ida Wahidah. (2025). Pengembangan Model Convolutional Neural Network (CNN) untuk Klasifikasi Penyakit Kulit Berbasis Citra Digital. *Infotek: Jurnal Informatika Dan Teknologi*, *8*(1), 298–308. https://doi.org/10.29408/jit.v8i1.28655

Islam, S., Mahmud, M. Z., Alve, S. R., Chowdhury, Md. M. U., & Oishe, F. I. (2024). Deep Learning Approach for Enhancing Oral Squamous Cell Carcinoma with LIME Explainable AI Technique. *Arxiv*. http://arxiv.org/abs/2411.14184

Iswantoro, D., & Handayani UN, D. (2022). Klasifikasi Penyakit Tanaman Jagung Menggunakan Metode Convolutional Neural Network (CNN). *Jurnal Ilmiah Universitas Batanghari Jambi*, *22*(2), 900. https://doi.org/10.33087/jiubj.v22i2.2065

Khanam, F. T. Z., Al-Naji, A., Perera, A. G., Wang, D., & Chahl, J. (2023). Non-invasive and non-contact automatic jaundice detection of infants based on random forest. *Computer Methods in Biomechanics and Biomedical Engineering: Imaging and Visualization*, *11*(6), 2516–2529. https://doi.org/10.1080/21681163.2023.2244601

Kirana, K. C. (2021). *Pengolahan Citra Digital* (A. H. Nadana, Ed.). Ahlimedia Press.

Kramer, L. I. (1969). Advancement of Dermal Icterus in the Jaundiced Newborn. *Archives of Pediatrics & Adolescent Medicine*, *118*(3), 454. https://doi.org/10.1001/archpedi.1969.02100040456007

Musthafa, M. M., T R, M., V, V. K., & Guluwadi, S. (2024). Enhanced Skin Cancer Diagnosis Using Optimized CNN Architecture and Checkpoints for Automated Dermatological Lesion Classification. *BMC Medical Imaging*, *24*(1). https://doi.org/10.1186/s12880-024-01356-8

Nurcahyati, I., Saragih, T. H., Farmadi, A., Kartini, D., & Muliadi. (2024). Classification of Lung Disease in X-Ray Images Using Gray Level Co-Occurrence Matrix Method and Convolutional Neural Network. *Journal of Electronics, Electromedical Engineering, and Medical Informatics*, *6*(4), 332–342. https://doi.org/10.35882/jeeemi.v6i4.457

Nurfita, R. D., & Ariyanto, G. (2018). Implementasi Deep Learning berbasis Tensorflow untuk Pengenalan Sidik Jari. *Emitor: Jurnal Teknik Elektro*, *18*(1), 22–27. https://doi.org/10.23917/emitor.v18i01.6236

Nurhikmat, T. (2018). *Implementasi Deep Learning untuk Klasifikasi Citra Menggunakan Algoritma Convolutional Neural Network (CNN) pada Gambar Wayang Golek*. https://doi.org/10.13140/RG.2.2.10880.53768

Nurona Cahya, F., Hardi, N., Riana, D., & Hadianti, S. (2021). Sistem Informasi Klasifikasi Penyakit Mata Menggunakan Convolutional Neural Network (CNN). *SISTEMASI*. http://sistemasi.ftik.unisi.ac.id

Pramestya, R. H. (2018). *Deteksi dan Klasifikasi Kerusakan Jalan Aspal Menggunakan Metode YOLO Berbasis Citra Digital*. Institut Teknologi Sepuluh Nopember.

Prastika, I. W., Zuliarso, E., Lomba, J. T., No, J., & 50241, S. (2021). Deteksi Penyakit Kulit Wajah Menggunakan Tensorflow dengan Metode Convolutional Neural Network. *Jurnal Manajemen Informatika & Sistem Informasi)*, *4*(2). http://e-journal.stmiklombok.ac.id/index.php/misi

Pratama, R. R. (2020). Analisis Model Machine Learning Terhadap Pengenalan Aktifitas Manusia. *MATRIK : Jurnal Manajemen, Teknik Informatika Dan Rekayasa Komputer*, *19*(2), 302–311. https://doi.org/10.30812/matrik.v19i2.688

Rahman, H., Ahmad, I., Jon, P. H., Rabbi, M. F., & Salam, A. (2024). Automated Detection of Selected Tea Leaf Diseases by Digital Image Processing Using Convolutional Neural Network (CNN): Bangladesh Perspective. *Research Square*. https://doi.org/10.21203/rs.3.rs-3869855/v1

Ramadhanty, J., & Puspitasari, T. D. (2022). Sistem Informasi Diagnosis Ikterus Neonatorum Menggunakan Logika Fuzzy. In *Jurnal Teknologi Informasi dan Terapan (J-TIT* (Vol. 9, Issue 1). https://doi.org/10/25047/jtit.v8i2.187

Riskesdas. (2015). *Riset Kesehatan Dasar*.

Rufaindah, E., Muzayyana, Sulistyawati, E., Hasnita, Y., Sari, N. A., Citrawati, N. K., Yanti, N. L. G., Mustikawati, N., Mariyam, Meiriza, W., Wulandari, I. S., Patemah, Badiah, A., Oviana, A., Rahayu, S., & Mayasari, D. (2022).

Tatalaksana Bayi Baru Lahir (M. Martini, Ed.). Media Sains Indonesia. www.medsan.co.id

Suartika, I. W., Wijaya, arya Y., & Soelaiman, R. (2016). *Klasifikasi Citra Menggunakan Convolutional Neural Network (CNN) pada Caltech 101*. *5*, 65–69.

Sudana Putra, F., Otomatis Jerawat Wajah, D., & Kurniawan, M. P. (2021). Deteksi Otomatis Jerawat Wajah Menggunakan Metode Convolutional Neural Network (CNN). *JIFOTECH (JOURNAL OF INFORMATION TECHNOLOGY*, *1*(2).

Sugiarto, W., Kristian, Y., & Setyaningsih, E. R. (2018). Estimasi Arah Tatapan Mata Menggunakan Ensemble Convolutional Neural Network. *Teknika*, *7*(2), 94–101. https://doi.org/10.34148/teknika.v7i2.126

Sulistiyanti, S. R., Setyawan, F. A., & Komarudin, M. (2016). *Pengolahan Citra; Dasar dan Contoh Penerapannya*. Teknosain.

Wang, Y., Yang, L., Liu, X., & Yan, P. (2024). An improved semantic segmentation algorithm for high-resolution remote sensing images based on DeepLabv3+. *Scientific Reports*, *14*(1). https://doi.org/10.1038/s41598-024-60375-1

Weaver, L., Hamoud, A.-R., David, X., Stec, E., & Hinds, T. D. (2018). Biliverdin reductase and bilirubin in hepatic disease. *Am J Physiol Gastrointest Liver Physiol*, *314*, 668–676. https://doi.org/10.1152/ajpgi.00026.2018.-The

Wiederhold, G., & McCarthy, J. (2010). Arthur Samuel: Pioneer in Machine Learning. *IBM Journal of Research and Development*, *36*(3), 329–331. https://doi.org/10.1147/rd.363.0329

Wira, J., & Putra, G. (2020). *Pengenalan Konsep Pembelajaran Mesin dan Deep Learning* (1.4).

Xue, G., Zhang, H., Ding, X., Xiong, F., Liu, Y., Peng, H., Wang, C., Zhao, Y., Yan, H., Ren, M., Ma, C., Lu, H., Li, Y., Meng, R., Xie, L., Chen, N., Cheng,

X., Wang, J., Xin, X., … Wei, J. (2023). Parental detection of neonatal jaundice using a low-cost colour card: a multicentre prospective study. *BMJ Paediatrics Open*, *7*(1). https://doi.org/10.1136/bmjpo-2023-001924

Yu, L., Zeng, Z., Liu, A., Xie, X., Wang, H., Xu, F., & Hong, W. (2022). A Lightweight Complex-Valued DeepLabv3+ for Semantic Segmentation of PolSAR Image. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, *15*, 930–943. https://doi.org/10.1109/JSTARS.2021.3140101

Zhang, H., Zhuang, Y., Xia, S., & Jiang, H. (2023). Deep Learning Network with Spatial Attention Module for Detecting Acute Bilirubin Encephalopathy in Newborns Based on Multimodal MRI. *Diagnostics*, *13*(9). https://doi.org/10.3390/diagnostics13091577